多媒体与智能交互

最终背诵版：带单位

```
声音数据量(Byte)
= 采样频率(Hz) × 量化位数(bit/样本) × 声道数 × 时间(s) ÷ 8
声音速率(bit/s)
= 采样频率(Hz) × 量化位数(bit/样本) × 声道数
采样点总数(个)
= 采样频率(Hz) × 时间(s) × 声道数
像素总数(个)
= 宽度(像素) × 高度(像素)
图像数据量(Byte)
= 宽度(像素) × 高度(像素) × 每像素位数(bit/像素) ÷ 8
RGB图像数据量(Byte)
= 宽度(像素) × 高度(像素) × 3(Byte/像素)
YUV 4:4:4 样本数(个)
= 3 × W(像素) × H(像素)
YUV 4:2:2 样本数(个)
= 2 × W(像素) × H(像素)
YUV 4:1:1 样本数(个)
= 1.5 × W(像素) × H(像素)
YUV 4:2:0 样本数(个)
= 1.5 × W(像素) × H(像素)
视频总帧数(帧)
= 帧率(fps，帧/秒) × 时间(s)
视频数据量(Byte)
= 宽度(像素) × 高度(像素) × 每像素位数(bit/像素) × 帧率(fps) × 时间(s) ÷ 8
视频码率(bit/s)
= 宽度(像素) × 高度(像素) × 每像素位数(bit/像素) × 帧率(fps)
码率(bit/s)
= 文件大小(Byte) × 8 ÷ 时间(s)
文件大小(Byte)
= 码率(bit/s) × 时间(s) ÷ 8
压缩比
= 原始大小(Byte) ÷ 压缩后大小(Byte)
宏块数(个)
= ceil[宽度(像素) ÷ 16] × ceil[高度(像素) ÷ 16]
运动矢量(像素)
= 匹配块位置(像素) - 当前块位置(像素)
```

A001 多媒体与智能交互 案例概述

1. 什么是交互

   所谓交互，即输入(input)和输出(output)。交互设计(Interaction Design)就是针对输入方式(通常是人)和输出方式(通常是机器)的设计。

   在人与计算机之间搭建一个有效的交流媒介。
   遵循一系列的界面设计原则，定义界面对象和界面动作，然后创建构成用户界面原型基础的屏幕布局。交互设计要符合用户习惯，改进或引导用户达到目标，并且过程要有效率并能让用户感到愉悦。

2. 媒体与交互密不可分。
3. 互联网思维带来的三大改变 互联网思维的 13 条法则
4. 交互方式的变化：鼠标、键盘退场，无需学习的自然交互，被动交互，协同交互

设计一个案例：

智能食堂营养取餐交互系统

场景： 高校食堂取餐区。
学生打饭时，系统通过摄像头识别餐盘里的菜品，结合电子秤估算份量，在屏幕上显示热量、蛋白质、碳水、脂肪等信息。

多媒体交互体现：

- 图像输入：识别菜品；
- 触摸输入：选择是否有减脂、增肌、忌口等需求；
- 语音输出：提醒“今日蔬菜摄入偏少”；
- 屏幕输出：显示营养图表；
- 灯光反馈：绿色表示搭配均衡，黄色表示偏油或偏咸。

智能性： 系统能根据学生选择的目标，智能判断当前餐盘是否合理，并推荐“可以再加一份蔬菜”或“主食已经足够”。

可行性： 菜品识别、电子秤、触摸屏和语音播报技术都比较成熟，可以先在一个食堂窗口试点。

实用性： 能帮助学生养成健康饮食习惯，也能辅助学校食堂了解学生饮食结构，改进菜品搭配。

UI设计分析

信息太多 → 米勒定律；

选项太多 → 希克定律；

分组混乱 → 接近法则；

按钮不明显 → 费茨定律；

没有提示 → 防错原则 / 信息反馈。

表单界面：

1. 输入框和标签是否靠近 → 接近法则；
2. 提交按钮是否明显 → 费茨定律；
3. 是否有必填提示 → 防错原则；
4. 输入错误是否实时反馈 → 信息反馈；
5. 表单是否太长 → 米勒定律 / 泰斯勒定律。

APP 首页

重点写：

1. 功能入口是否太多 → 希克定律；

2. 信息是否分组清楚 → 接近法则；
3. 重要功能是否突出 → 视觉层级 / 费茨定律；
4. 图标风格是否统一 → 一致性原则；
5. 是否有多余装饰 → 奥卡姆剃刀。

B001 多媒体技术-基础理论技术

1. 什么是多媒体

   媒体：承载信息的载体。
   信息的传播和存储形式是多种多样的，
   即信息表现的媒体是多种多样的。

   多媒体的定义
   多媒体(Multimedia)是融合两种或者两种以上媒体的一种人 - 机交互式的信息交流和传播媒体。

   多媒体技术的定义
   多媒体技术是指能够在同一环境中获取、处理、存储、输出文本、图形、图像、音频和视频等多种媒体信息，并在这些媒体间建立逻辑联系，集成为一个具有交互性的系统的技术。

2. 媒体的分类

   分类方法1：CCITT(国际电联)定义五种类型：
   感觉媒体，表示媒体，显示媒体，存储媒体，传输媒体

   分类方法2：人类是利用视觉、听觉、触觉、嗅觉、味觉来感受各种信息的。
   视觉类媒体：通过视觉传达信息的媒体。如文字、点阵图像、矢量图形、动画、视频等；
   听觉类媒体：通过声音传达信息的媒体。如波形声音、语音、音乐、
   触觉类媒体：指环境媒体，不通过视觉和听觉，仍可以接受和传递信息。如皮肤可感受环境温度、湿度、压力，身体可感受振动、运动、旋转等。例子：MIT 触觉手套。
   嗅觉类媒体正在研究之中。例子：电子鼻，Nos.e。
   味觉类媒体正在研究之中。

3. 多媒体涉及的几个概念

   超媒体：多媒体+超文本：元宇宙是第三代互联网。

   新媒体：媒体形态的一种，以数字技术为基础，网络为载体所有人对所有人进行传播

   跨媒体：跨媒体传播是指信息在不同媒体之间的流布与互动。

   三种形式的跨越，不同类型数据，不同来源数据，信息空间和物理世界之间的跨越。

   跨媒体一致性表达 跨媒体检索与排序 阿里达摩院Proxima

   网络媒体、移动媒体、自媒体

   多媒体与社交网络 云计算 物联网与大数据 存储 云存储

4. 多媒体主要研究领域和发展趋势

   多媒体的应用领域：家庭 通信 教育 商业和企事业 出版业 医疗卫生 军事 虚拟现实

   发展趋势：

B002 多媒体技术-元宇宙 虚拟人

1. 元宇宙的概念与定义

   元宇宙是一个网络化的虚拟现实balabla

   元宇宙是整合多种新技术而产生的新型虚实相融的互联网应用和社会形态，它基于，，，，

2. 元宇宙应用场景

游戏 社交 内容 消费

3. 元宇宙的技术底座
4. 元宇宙六大支撑技术：BIGANT
5. 元宇宙风险与挑战
6. 现有技术和产品案例

   虚拟人 / 虚拟化身
7. 从 8 个类别追踪元宇宙发展

B003 多媒体技术-基础理论技术-信息编码

信息是对发生事件的抽象描述，而数据是在确定了描述方法后对事件的具体描述记录。对同一个信息，若使用的描述方法不同，则形成记录的数据量可能完全不同。

1. 数据压缩算法的分类(重点)：

无损压缩：
采用减少冗余数据而达到压缩目的。
压缩后的数据进行重构所得到的数据与原数据完全相同。即压缩和还原的过程是可逆的。
有损压缩：
采用减少冗余数据和部分信息而达到压缩目的。
压缩后的数据进行重构所得到的数据与原数据有所不同，但不会对原始资料表达的信息造成误解。
减少的信息量是不可恢复的。

信息论压缩思想：

重点句

> 概率大用较短编码，概率小用较长编码。

也就是：

- 出现频率高的符号，给短编码；
- 出现频率低的符号，给长编码；
- 这样总体编码长度更短。

是熵的概念用于信息压缩的重要原理。

1. 香农—范诺算法
2. Huffman 编码
3. 算术编码
4. RLE 编码
5. 词典编码
   - 第一类算法——指针形式

     LZ77、LZSS
   - 第二类算法——索引形式

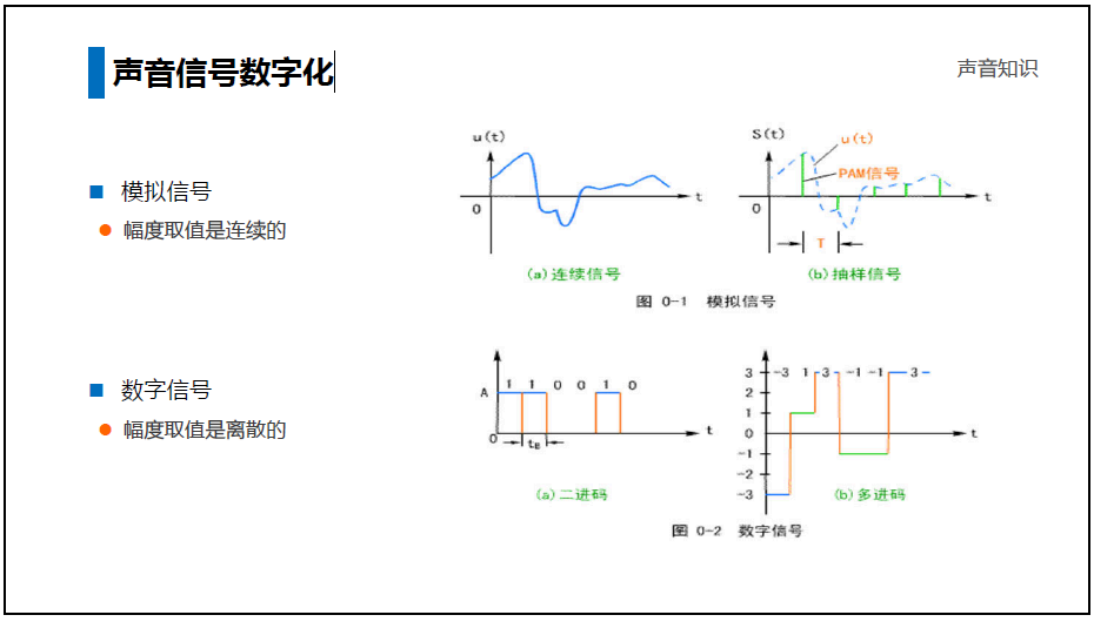
     LZ78、**LZW**

B101 多媒体技术-基础理论技术-声音

声音是携带信息的及其重要的媒体。
声音的基础知识，重点掌握声音数字化的两个最基本的概念；
声音的特性、应用等。

两个参数:频率和幅度
1)人能够听到的是20~20 000Hz，0~120dB
2)话音信号:300~3000Hz(人说话的频率)

话音编码(声音的数字化):
数字化声音的基本方法



声音的数字化的定义/什么是声音数字化
将具有一定振幅和频率的连续变化的模拟声音信号，通过A/D转换器，以一定的频率对模拟音频信号截取一个振幅值，并用指定字长的二进制位表示，从而将连续的模拟音频信号转变成能被计算机处理的，离散的数字音频信号。

为什么要使用数字信号?
1、数字信号计算是一种精确的运算方法，它不受时间和环境变化的影响；
2、表示部件功能的数学运算相对容易实现；
3、对数字运算部件进行编程，如欲改变算法或改变某些功能，还可对数字部件进行再编程。

声音数字化过程的步骤:

数字化过程

声音数字化过程包括采样(抽样)和量化两个步骤。

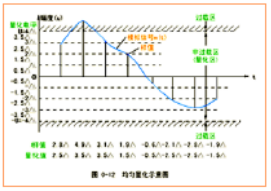
- **采样**:
  - 截取模拟声音信号振幅值的过程称为采样，所得到的振幅值称为采样值。
- **量化**:
  - 采样值用二进制位表示称为量化。

奈奎斯特理论(定理):
采样频率须大于等于声音信号截止频率(最高频率)的2倍，这样就能把以数字表达的声音还原成原来的声音，称为无损数字化。

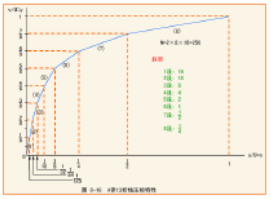
量化方法

量化阶距的特点

- 均匀量化



- 非均匀量化



声音质量与数据率:

与声音质量有关的重要因素
1)采样频率：每秒钟内所采样的次数
采样频率越高，则单位时间内获取的样本数越多，数字化后的音频信号就越逼真，但所需要的存储量也越大。
2)量化位数：表示每个采样样本的二进制位数
量化位数多，噪声低，但所需要的存储量也越大。
3)声道数：采样时声音通道的个数
立体声效果更真实，但数据量将成倍增加。

声音质量的度量

声音知识

- **声音质量度量**的基本方法有**两种**:
  - 1、**客观质量度量**：用信噪比(SNR) 度量。
  - 2、**主观质量度量**：主观平均判分法(MOS)。

信噪比(SNR)

MOS

由若干实验者对声音质量进行评分，以平均值作为其质量的度量值。

分数	质量级别	失真级别
5	优(Excellent)	无察觉
4	良(Good)	(刚)察觉但不讨厌
3	中(Fair)	(察觉)有点讨厌
2	差(Poor)	讨厌但不反感
1	劣(Bad)	极讨厌(令人反感)

声音质量等级与数据率 (P11)

数据率? (kb/s)

- 通常分为5级:
  - 电话
  - 调幅广播
  - 调频广播
  - 光盘(CD)
  - 数字录音带
    - (DAT, Data Audio Tape)

质量	采样频率(kHz)	样本精度(bit/s)	单道声/立体声	数据率(未压缩)(kb/s)	频率范围
电话*	8	8	单道声	64	200～3 400 Hz
AM	11.025	8	单道声	88.2	50～7 000Hz
FM	22.050	16	立体声	705.6	20～15 000Hz
CD	44.1	16	立体声	1411.2	20～20 000 Hz
DAT	48	16	立体声	1536.0	20～20 000 Hz

* 电话使用μ律编码，动态范围为13位，而不是8位(详见第3章)

声音文件的数据量:

声音文件的数据量=(采样频率× 量化精度× 声道数× 时间)/ 8
采样频率单位： – Hz
时间单位： – 秒
数据量单位: – 字节



蓝牙的带宽：

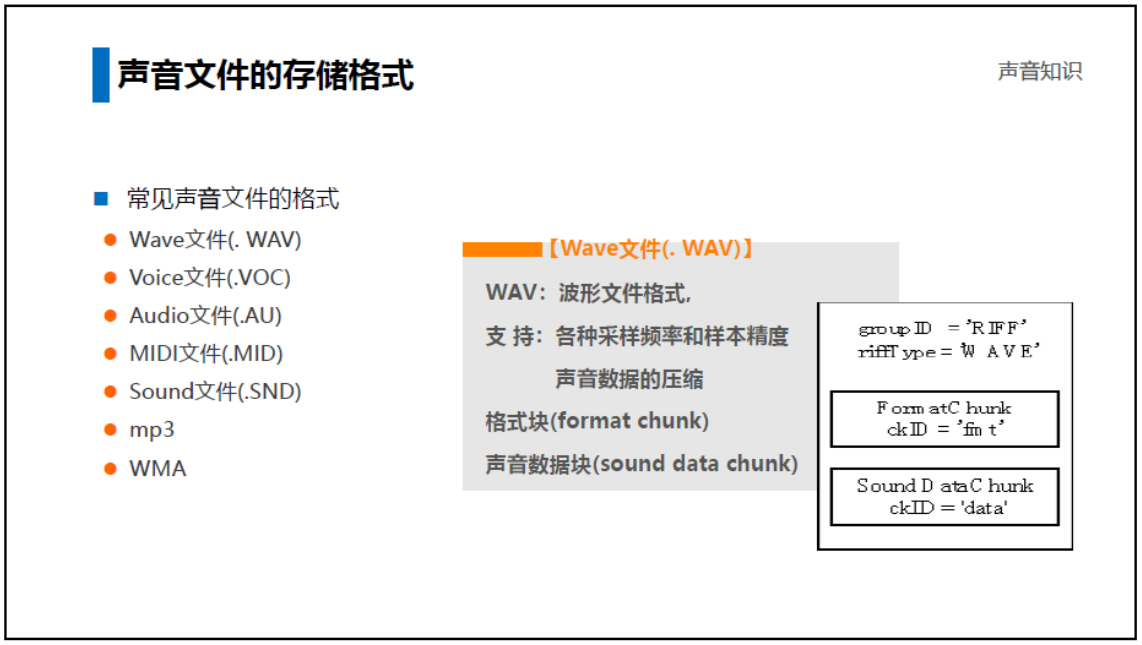
安卓常见的APTX蓝牙编码，经过传输过后的音频文件码率只能达到352kbps，在音质方面也只是略好于320kbps的MP3格式，远达不到无
损的标准。随着未来蓝牙协议的升级，带宽提上去了，HiFi格式播放也指日可待。

常见音频编码

- SBC：挺早的蓝牙音频编码，也是运用最广泛的编码格式。采用SBC编码的蓝牙耳机，一般都有比特率较低、压缩率较高的问题，用这一编码传输之后的音乐细节基本上大量损失，音乐听感也很差。
- AAC：AAC编码的出现，目的是为了取代MP3格式，在同一码率
  下AAC的听感要优于MP3。目前市面上主流AAC播放的设备，
  大部分都来自于苹果。
- aptX：aptX有着低延时的特性，在其母公司被高通收购之后，广泛的应用于安卓手机平台上；aptX编码还有一些细分的格式，其中一种名为aptX HD的编码格式可以达到24 bit 48KHz的音频格式，基本达到“CD”级别的聆听体验。
- LDAC：LDAC是索尼推出的无线音频编码技术，理论传输速率最高可达990kbps，高出SBC三倍之多，这也是目前最接近无损（无损音质：1411kbps）的编码格式。
- HWA：华为提出的HWA是继aptX HD、LDAC之后，第三家蓝牙高音
  质协议。HWA提供三种码率模式，分别是400kbps、500kbps/560kbps
  与900kbps。

一张图看懂解码参数

协议	延迟	采样频率
SBC	220ms	44.1KHz&16bit LPCM audio
AAC	120ms-150ms	44.1KHz&16bit LPCM audio
aptX	60ms-80ms	48KHz&16bit LPCM audio
aptX-LL	<40ms	48KHz&16bit LPCM audio
aptX-HD	>100ms	48KHz&24bit LPCM audio



感知声音编码：

根据波形本身得相关行和模拟人的发音器官的特性进行编码

利用人的听觉系统的特性达到压缩声音数据的目的

听觉系统三个感知特性

1. 响度
    - 声音的强弱；
2. 音高
    - 用频率表示声音高低；
3. 掩蔽效应
    - 一种频率的声音阻碍听觉系统感受另一种频率声音的现象。

响度

声音的强弱

- (1) 物理度量：用客观测量单位来度量。
- (2) 心理度量：用人心理上主观感觉的声音强弱度量。
  - 方(Phon) 或 宋(sone)

- 响度的相对量称为响度级，表示某响度与基准响度比值的对数值。
  - 1kHz纯音的声强达到10^{-16}W/cm2(即0dB声强)时，**人耳刚好能听到，响度就定义0方。**
  - 1kHz纯音的声强达到10^{-4}W/cm^2(即120dB声强)时，**人耳感到疼痛，响度定义为120方。**

听阈

声音弱到刚好能被人耳听到时的强度。

痛阈

声音强到让人耳感到疼痛时的强度。

听觉范围

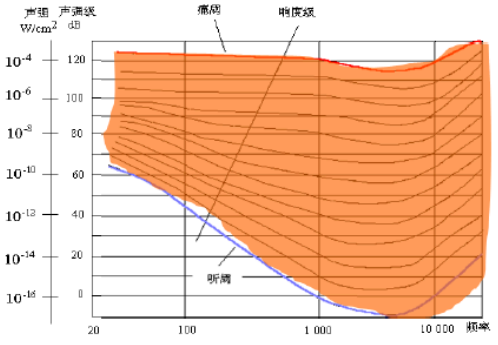
> 听阈—频率曲线与痛阈—频率曲线之间的区域。

听(痛)阈是随频率变化

特点

MPEG声音

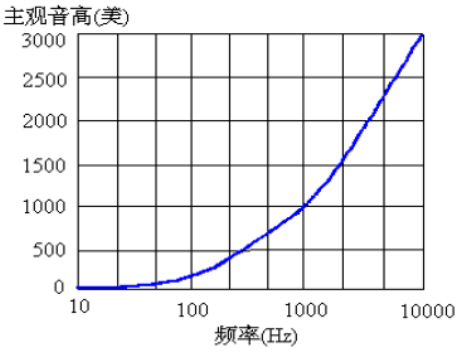
- **听觉范围**
  - “听阈-频率”曲线与“痛阈-频率”曲线之间的区域。
- **主观感觉与频率紧密相关**
  - 2kHz～4kHz范围的声音最敏感，幅度很低的声音信号都能听到；
  - 低频信号和高频信号则幅度要高得多才能听到。
  - 语音信号能量主要集中在500～1000Hz范围左右。



10.1.2 听觉系统对音高的感知特性

MPEG声音

- 音高的客观度量与主观度量
  - 客观度量：
    - 振动速度(频率)表示声音的音高，单位Hz
  - 主观度量：
    - 用人耳对音高的主观感觉确定，单位Mel(美)
    - Mel=1000log2(1+f)
- 2.客观音高(频率)与主观音高的关系
  - 主观音高与频率(客观音高)
    - 不是线性关系，“音高-频率”
    - 对数曲线



掩蔽效应：
频域掩蔽

一个强纯音会掩蔽附近同时发声的弱纯音。

特点：

弱纯音离强纯音越近，掩蔽越明显；
低频纯音可以有效掩蔽高频纯音；
高频纯音对低频纯音掩蔽不明显。
时域掩蔽

时间上相邻声音之间的掩蔽现象。

分为：

超前掩蔽；
滞后掩蔽。

产生时域掩蔽的原因：大脑处理信息需要一定的时间。

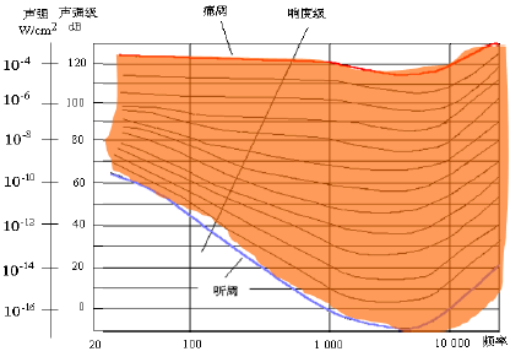
掩蔽效应是心理声学模型的基础。

特点

人耳的听觉范围

听(痛)阈是随频率变化

- **听觉范围**
  - “听阈-频率”曲线与“痛阈-频率”曲线之间的区域。
- **主观感觉与频率紧密相关**
  - 2kHz～4kHz范围的声音最敏感，幅度很低的声音信号都能听到；
  - 低频信号和高频信号则幅度要高得多才能听到。
  - 语音信号能量主要集中在500～1000Hz范围左右。



作用

- 人类在利用自身的听觉系统的特性来压缩声音数据方面取得了很大的进展，先后制定了MPEG-1 Audio，MPEG-2 Audio和MPEG-2 AAC等标准。

- 听觉系统的感知特性，掩蔽效应
- MPEG Audio与感知特性
- MPEG-1 Audio
- MPEG-2 Audio
- MPEG-2 AAC(MPEG2的新扩展)
- MPEG-4 Audio

MPEG Audio是指MPEG1Audio，MPEG2AudioheMPEG-2AAC，处理10~20000kHz范围里的声音数据。

一、MPEG Audio与心理声学模型

MPEG Audio使用心理声学模型来实现压缩声音数据的目的。

二、心理声学模型的要点

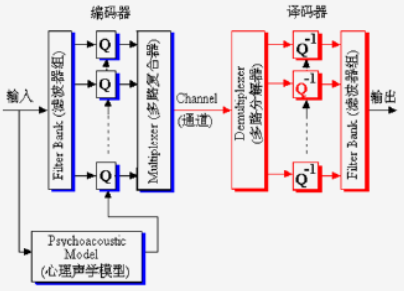
1.考虑了听觉阈值的概念：听觉系统中存在一个听觉阈值电平，低于这个电平的声音信号人就听不到，因此可以去掉这部分信号而不会影响人对声音信息的获取。

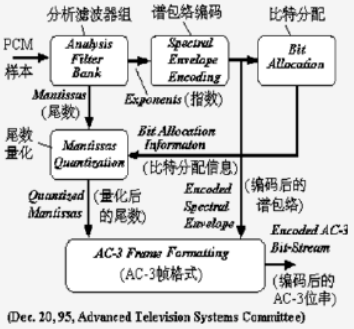
2.利用了听觉的掩蔽特性：人的听觉系统感觉不到强声中的轻声。所以，当多种频率声音存在时，凡是被掩蔽的声音均可以去掉。

MPEG Audio 采用两种感知编码

MPEG声音

- **感知子带编码：**
  - 通过滤波器组后分割成许多子带
  - 每个子带对应一个编码器，根据心理声学模型进行编码。
- 杜比实验室开发的**DolbyAC-3编码**
  - 一种多通道(multichannel)音乐信号压缩技术，它可支持5个3~20000Hz频率范围的通道。





MPEG Audio压缩编码定义了3个层次，3个层次的基本模型相同。

层1：频域掩蔽

层2：频域掩蔽，时域掩蔽

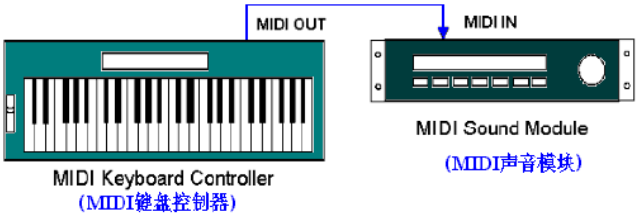
层3：频域掩蔽，时域掩蔽，立体声/声道数量

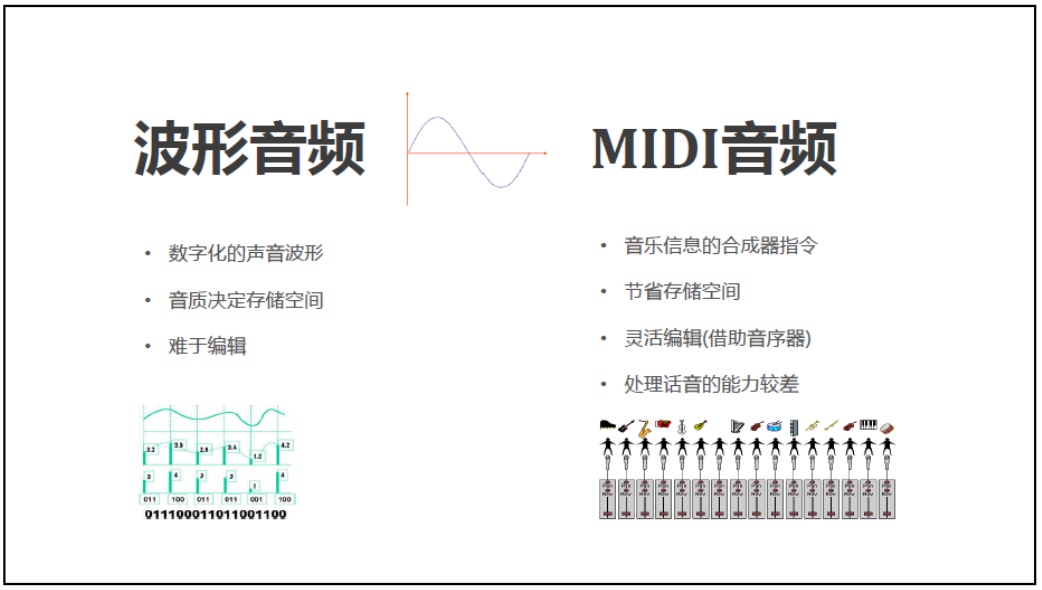
MIDI是什么：

电子乐器数字接口MIDI

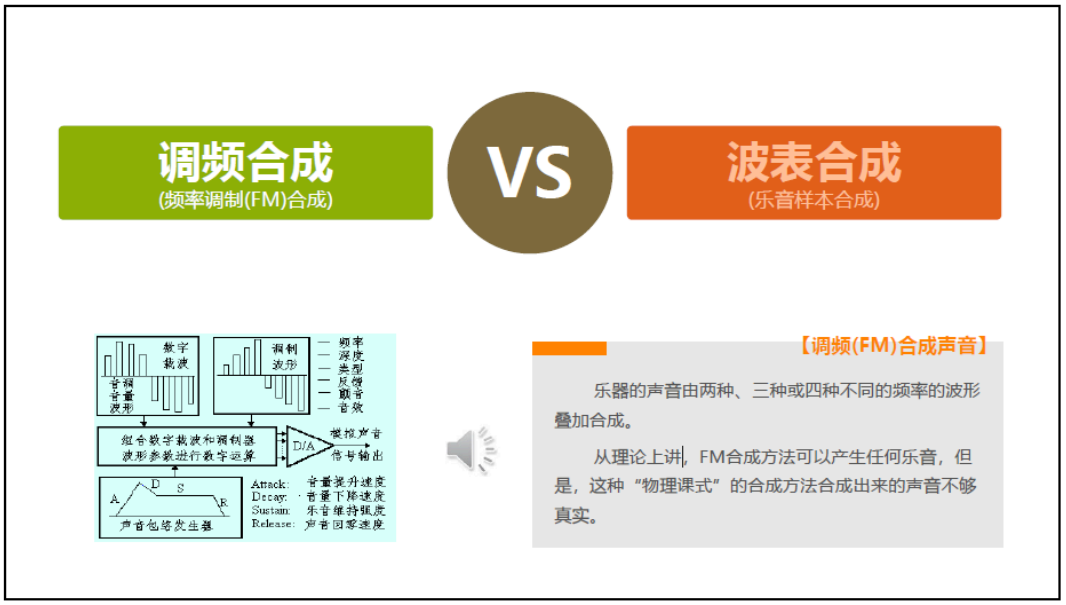
声音知识

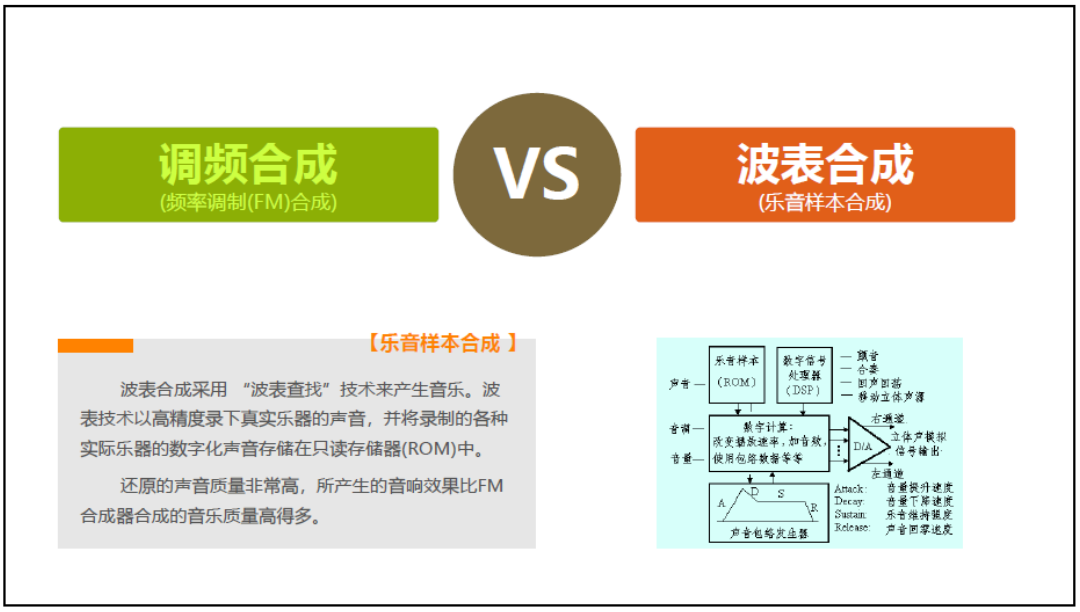
- 一套**指令**的约定，不是声音信号。
- MIDI标准于1983年8月5日正式制定(数字音乐国际标准)。
- 规定了音乐设备之间、音乐设备与计算机之间的连接电缆和硬件，还规定了音乐设备之间、音乐设备与计算机之间的**通信协议**。
- 各种音乐设备只要遵从MIDI标准配备MIDI信息处理器和MIDI接口，就能相互连接和通信。




波形音频
数字化的声音波形
音质决定存储空间
难于编辑
0111009011011001100
MIDI音频
音乐信息的合成器指令
节省存储空间
灵活编辑(借助音序器)
处理话音的能力较差

调频合成与波表合成：


调频合成
(频率调制(FM)合成)
VS
波表合成
(乐音样本合成)
【调频(FM)合成声音】
乐器的声音由两种、三种或四种不同的频率的波形叠加合成。
从理论上讲，FM合成方法可以产生任何乐音，但是，这种“物理课式”的合成方法合成出来的声音不够真实。



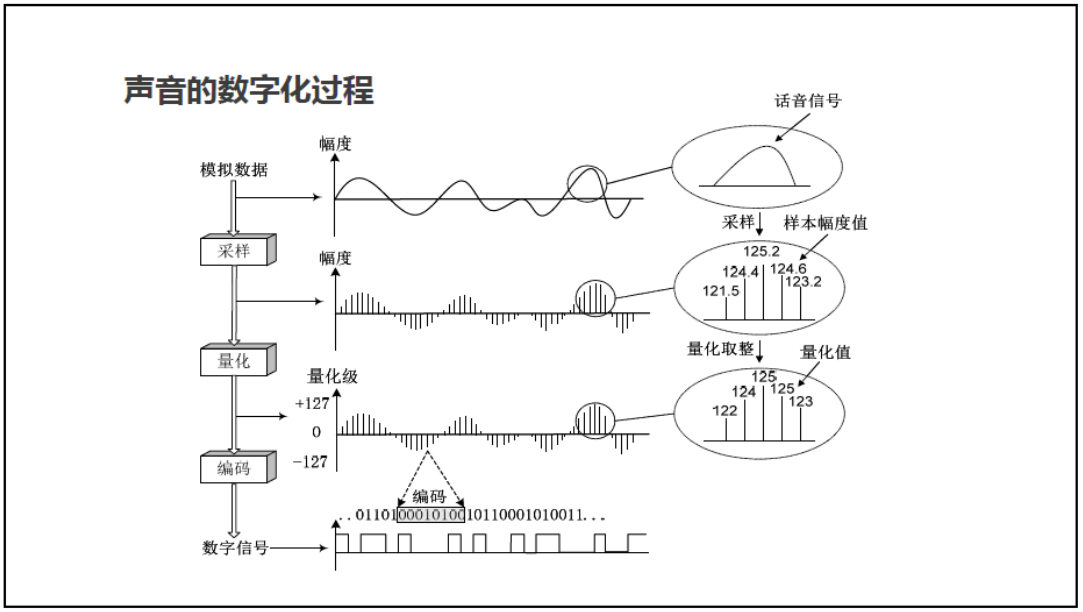


通道：
一个通道指一条独立的信息传输路线。单个物理MIDI通道分成16个逻辑通道，每个通道访问一个独立的逻辑合成器，可充当一种乐器的角色。

B102 多媒体技术-基础理论技术-话音编码

为了在不明显降低话音质量的前提下，减少存储空间、提高数据传输率，需要对话音信号进行压缩编码。

压缩空气通过声门激励声道滤波器，根据激励方式的不同，话音分成三种类型。
浊音，清音，爆破音



音频编码三大类

PPT 中列出三大类：

类型	特点
波形编码	质量高，但数据率高
参数编码	数据率低，但合成语音质量较差
混合编码	质量和数据率介于二者之间

这一章主要涉及**波形编码。**

PCM：脉冲编码调制

核心思想

> PCM是对音频信号采样、量化后不作其它处理直接以数字化格式存储。

特点：

不压缩；质量高；数据量大；采用均匀量化。

主要问题：为了提高音质，就必须提高音频信号的采样精度，即增加量化位数，但数据量会明显增加。

μ律 / A律

这是非均匀量化。

为什么需要它?

因为语音信号的大部分信息集中在低幅度区域。

所以：

小信号：用小量化阶距，精细编码；
大信号：用大量化阶距，粗略编码。

APCM：自适应脉冲编码调制

核心思想

> 根据输入信号幅度大小，自动改变量化阶距。

也就是：

- 信号变化大，用大量化阶距；
- 信号变化小，用小量化阶距。

差分脉冲编码调制(DPCM)

根据过去的样本值估算出预测值，然后对预测值和实际样本值的差值编码，从而降低音频数据的编码率，达到压缩目的。 利用样本与样本之间存在的信息冗余度来进行编码的一种数据压缩技术。

自适应差分脉冲编码调制(ADPCM)

1、差分量化：利用相邻样值之间的差值进行量化。
2、自适应量化：
• 使量化器自动适应输入电平的变化，随时估计输入信号的时变幅度，以修正量化阶距，当输入信号与预测信号的差值小时，使用小的量化阶距，差值大时，使用大的量化阶距。

G.721 ADPCM 标准：实现64kb/s A律/μ律PCM与32kb/s ADPCM之间的转换。压缩率2:1 。

子带编码(SBC)

子带编码将整个音频频带分成若干个子带，分别对每个子带信号进行编码，然后由多路编码器将各子带编码复合后输出。

1. 分解频带为多个子带
2. 对每个子带编码(ADPCM,APCM,PCM)
3. 复合子带
4. 接收端，每个子带单独译码，然后组合，还原成原来的音频信号。

G.722 SB-ADPCM编译码器

用正交镜像滤波器把音频频带分割成高频子带和低频子带，均采用DPCM编码。

增量调制(DM)与自适应增量调制(ADM)

基本思想：
根据当前信号预测下一个信号，产生一个预测值，对实际值与预测值之差的极性进行编码。
• 输入信号实际值≥预测值：x[i]=1
• 输入信号实际值< 预测值：x[i]=0

DM的主要问题：

1. 斜率过载：输出代码不能保持跟踪输入信号的快速变化。
2. 粒状噪声：输入信号与预测值的差值接近0的区域，输出出现随机交变的“0”和“1”的现象

思路1：
 加大量化阶距可避免斜率过载，但会加大粒状噪声；
 减少量化阶距可减少粒状噪声，但又使避免斜率过载更严重。

思路2：斜率的变化自动调整量化阶距的大小？
 提出了自适应增量调制的编码思想。

	算法	名称	数据率	标准	应用	质量
波形编码	PCM	脉冲编码调制			公共网 ISDN配音	4.0~4.5
	μ-law，A-law	μ-律，A-律	64kbps	G.711		
	APCM	自适应脉冲编码调制				
	DPCM	差分脉冲编码调制				
	ADPCM	自适应差分脉冲编码调制	32kbps	G.721		
	SB-ADPCM	子带-自适应差分脉冲编码调制	64kbps	G.722		
			5.3kbps 6.3kbps	G.723		
音源(参数)编码	LPC	线性预测编码	2.4kbps		保密话声	2.5 ~ 3.5
混合编码	CELPC	码激励LPC	4.6kbps		移动通信	4.0~3.7
	VSELP	矢量和激励LPC	8kbps		语音邮件	
	RPE-LTP	规则码激励长时预测	13.2kbps		ISDN	
	LD-CELP	低延时码激励LPC	16kbps	G.728 G.729		
	MPEG	多子带，感知编码	128kbps		CD	5.0
	Dolby AC-3	感知编码			音响	5.0

声音怎么从“波形”变成机器能识别的特征。

1. 声音是很多频率混在一起的

比如一句话，不是一个简单波，而是很多频率叠加出来的。

2. 用傅里叶变换拆开

傅里叶变换可以把复杂声音拆成不同频率成分。

频谱图就是把声音按时间切成很多小片，比如每 20ms 分析一次有哪些频率。

声音可以通过频谱图表示，方便神经网络等模型处理。

B103 多媒体技术-基础理论技术-声音各领域的研究情况

1. 音频功率放大器

   把较弱的音频信号放大，推动音箱发声。

2. 声音转换成特征以后，可以用于深度学习及各种应用。

   会议系统：高质量的降噪效果和实时处理性能是视频会议中音频降噪的两大挑战。

   AI学习心脏病喘息声

其他领域：

领域 1：语音识别 / 声音生成

语音识别：

把人说的话转换成文字。

应用：

微软语音识别系统单词错误率 WER 达到 5.9%，接近人类水平。
讯飞听见；

翻译机

语音助手

深度学习语音识别：

深度学习进行语音识别的核心，是将声音录音输入神经网络，然后训练神经网络来生成文本。
难点：

语音会随着速度变化。

TTS：文本转语音

把文字转换成语音。

根本问题：自然度。

TTS 应用：信息咨询；电话银行；办公自动化；人机交互。

TTS 项目：

项目　　作用
GPT-SoVITS　1 分钟克隆你的声音
Multi-voice-TTS-GPT-SoVITS　　多语种文本转语音，支持中日英等
MeloTTS 高质量多语言文本转语音库
Clone-Voice　用指定音色合成语音，也可声音转换
EmotiVoice　网易开源 TTS，可调整感情、语气、风格、速度、音高
OpenAI TTS　OpenAI 官方文本转语音简易项目

百度Deep Voice 3：全卷积注意力机制TTS系统

领域 3：声音的生成

声音克隆

MockingBird：5 秒之内克隆任意中文语音，并用这一音色合成新的说话内容。

假声音 / 变声

modulate.ai 。

把一个人的声音转换成另一种声音或指定音色。

和普通滤波器不同，PPT 说现在的变声技术加入了机器学习和深度学习，不再只是简单语音滤波。

假脸 + 假声音

假脸技术加上假声音后，可以生成真假难辨的假视频。

领域 4：虚拟主播 / 虚拟歌手

1. 央视 AI 手语主播
   来自百度智能云的虚拟数字人；
   为 2780 万听障人士提供 24 小时不间断手语服务；

2. AI 虚拟数字人直播

3. AI 配音

GAN 生成音乐

谷歌大脑团队用 GAN 生成高保真音乐。用生成对抗网络自动生成音乐。

5. 虚拟歌手

领域 5：多模态 / 物理领域

1. AI + 唇语

Meta 的 AV-HuBERT。

研究嘴部动作是否能提高语音识别性能；
AV-HuBERT 通过观看和听人们说话来理解语言。

2. AI + 图像处理：盲人辅助

3. 声镊技术

光镊 2018 年诺贝尔物理学奖与光镊技术有关；
光镊可以操控微小物体；
缺点是不能穿过非透明物质。

声镊技术可以克服光镊不能穿过非透明物质的缺点。

领域 6：声音的存储 / 获取方式

领域 7：身份认证

B201 多媒体技术-基础理论技术-数字图像

介绍表示数字彩色图像所需要的最基本的常识，以及目前使用得相当广泛的JPEG压缩标准。
1、视觉系统对颜色的感知
2、图象的颜色模型
3、图象的三个基本属性

分辨率(要求学会区分)
显色分辨率
图象分辨率

像数深度(图像深度)

正彩色，伪彩色，直接色。

图象分辨率：组成一幅图象的象素密度的度量方法:同样大小的一幅图，如果象素数目越多，图像的分辨率越高，看起来越逼真。

色彩深度：像数深度(图像深度)：指存储每个像素使用的位数。
用来度量图像的分辨率，决定每个像素可能有的颜色数，灰度图像的每个像素可能有的灰度级数。

常用的色深一般为：256色：8位，增强色：16位，64K色，真彩色：24位，16M。

真彩色(True Color)
组成一个图像的每个像素值中，有R，G，B三个基色分量，每个基色分量直接决定显示设备的基色强度，这样产生的彩色为“真彩色”。
RGB8:8:8,也称为全彩色。

α通道(alpha channel):又称为覆盖位(overlay),中断位，属性位。
– 除了RGB分量用固定位数表示外，还增加一位或几位为属性位，如RGB5:5:5表示一个像素时，用两个字节共16位表示，RGB各占一位，剩下一位位属性位，指定该像素具有的性质。

4、图象的种类

矢量图：

1)图形缩放后不变形：
– 矢量图形是以指令集合的形式描述的，图形缩放不会变形。
• 2)占用的存储容量小：
– 由于矢量图形只是存储的图形指令，所需的存储空间很小。
• 3)灵活性好：
– 构成矢量图形的各个部分是相对独立的，局部的处理不会影响其他部分。
• 4)表现能力有一定局限：
– 对于复杂而又不易用数学方法描述的对象，矢量图形就无能为力。显示速度比点位图慢。

点位图：

图像中的单个点称为像素(Pixel)，每个像素都有一个值，称为像素值，一个像素值往往用R，G，B三个分量表示。
每种基色的强度是用8位表示的，因此可产生2^24=16 777 216种颜色。

每个像数用若干各二进制位来指定该像素的颜色，亮度和属性。也称：位图、点阵图、图像、像素图。

点位图文件的大小：文件字节数=图像分辨率X图像（色彩）深度/8

点位图与矢量图的比较(知识点)：

位图图像效果好，放大会失真。
• 1)逼真
– 现实世界的任何物体，都是由许多微小的单元组成，点阵图由许多微小的像素构成，可以很真实的表现现实世界的任何对象。
• 2)占用的存储容量大
• 3)缺乏灵活性
– 像素之间无内在联系，如果把图像缩小，再恢复到原来的尺寸时，图像就会变得模糊不清。

矢量图效果差，放大不会失真。
• 1)图形缩放后不变形
– 以指令集合的形式描的。
• 2)占用的存储容量小
– 只是存储的图形指令。
• 3)灵活性好
– 各个部分是相对独立的，局部的处理不会影响其他部分。

• 4)表现能力有一定局限
– 对于复杂而又不易用数学方法描述的对象，矢量图形就无能为力。显示速度比点位图慢。

灰度图

按照灰度等级的数目来划分；只有黑白两种颜色叫单色图像；

每个像素不再存 RGB 三个颜色值，而是只存一个“亮度值”。比如 8 位灰度图。

颜色模型：

RGB (显示彩色图象用)
有源物体：一个能发出光波的物体称为有源物体，它的颜色由该物体发出的光波决定，使用RGB相加混色模型；
CMY(打印彩色图象用)
无源物体：一个不发光波的物体称为无源物体它的颜色由该物体吸收或者反射哪些光波决定，用CMY相减混色模型。

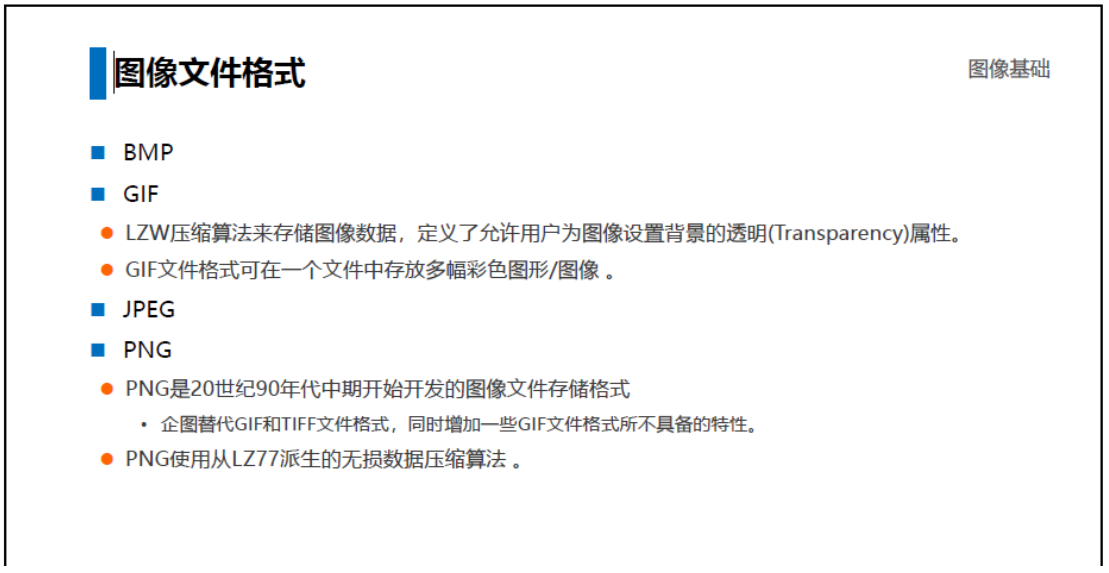
5、伽马校正
6、JPEG压缩编码

JPEG专家组开发了两种基本的压缩算法，
一种是采用以离散余弦变换(Discrete Cosine Transform，DCT)为基础的有损压缩算法。利用了人的视觉系统的特性。
一种是采用以预测技术为基础的无损压缩算法。

为了在保证图像质量的前提下进一步提高压缩比，JPEG 2000(简称JP 2000)标准中将采用小波变换(Wavelet)算法。

平面的图像，可以理解为除了水平X 和垂直Y 以外，还有一个色彩值的Z 的三维的系统。

7、图象文件格式



8. OpenCV：跨平台计算机视觉和机器学习软件库。

色彩空间转换；ROI 提取；不规则 ROI 提取；图像边缘保留滤波；图像梯度与边缘；视频分析与跟踪 DNN 模块；YOLO。

B202 多媒体技术-基础理论技术-颜色与色彩空间

1、视觉系统对颜色的感知

人的视网膜有对红绿蓝颜色敏感程度不同的三种锥体细胞和杆状细胞。红绿蓝三种锥体细胞对不同频率的光的感知程度不同，对不同亮度的感知程度不同。

2、图象的颜色模型

RGB模型：有源物体：一个能发出光的物体，它的颜色由该物体发出的广播决定。

CMY/CMYK模型：无源物体： 一个不发光的物体，它的颜色由该物体吸收或者反射哪些光波决定，用CMY相减混色模型；青色，品红，黄色；减少了为视觉系统识别颜色所需要的反色光。需要增加一种真正的黑色。K：纯黑。

HSB / HSL / HSV 模型：

HSB 模型，也讲 HSL、HSV。

HSL 表示：

H：Hue，色调；取决于可见光谱中的光波的频率，它是最容易把颜色区分开的一种属性。用于区别颜色的名称或颜色的种类。色调是视觉系统对一个区域呈现的颜色的感觉。
S：Saturation，饱和度；相对于明度的一个区域的色彩，是指颜色的纯洁性，它可用来区别颜色明暗的程度。当一种颜色渗入其他光成分愈多时，就说颜色愈不饱和。完全饱和的颜色是指没有渗入白光所呈现的颜色。例如，仅由单一波长组成的光谱色就是完全饱和的颜色。
L：Lightness，亮度 / 明度。视觉系统对可见物体辐射或者发光多少的感知属性。

3、图像的颜色空间

颜色空间是表示颜色的一种数学方法。

知识点：色彩空间

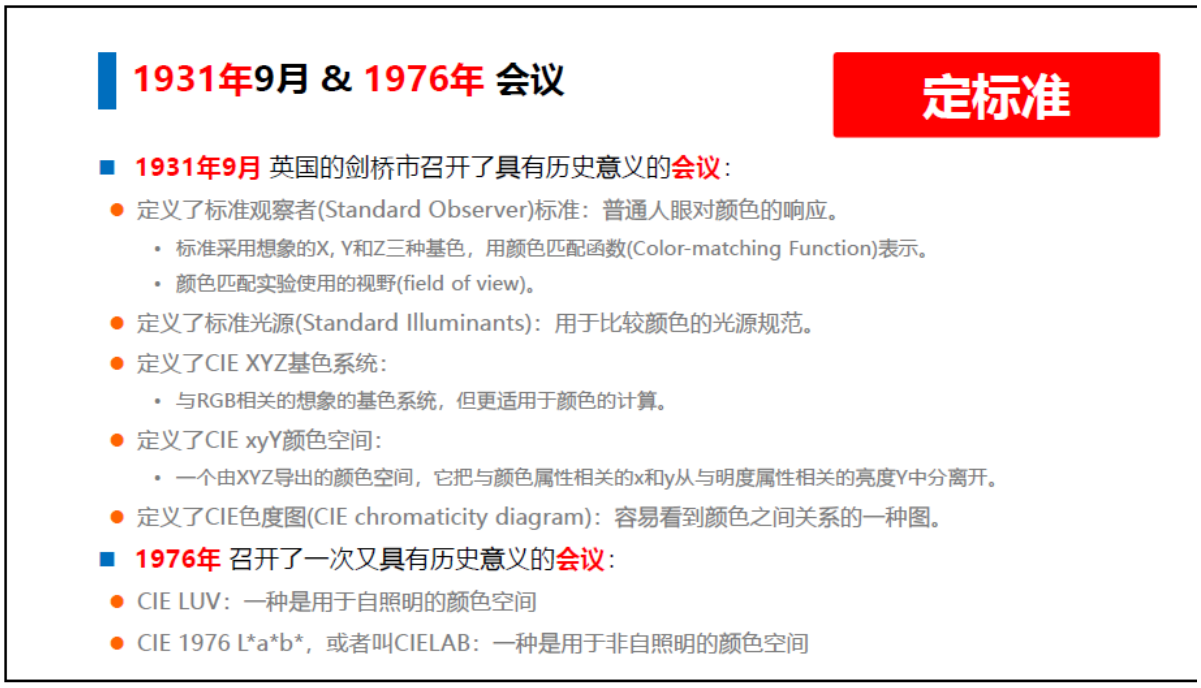
- **第一句话**，这个世界是没有色彩的，因为有了光，物质对光的反应才有了色彩。
- **第二句话**，色彩是人眼对光线的反应，受到很多条件的影响，是一种主观上的判断，无法准确量化，因此需要有一个标准的规范对色彩定义。
- **第三句话**，因为定义的不同，所以能表示的色彩范围也不同，这个就是色彩空间。

颜色度量体系：组织和表示颜色的方法主要有两种：
颜色模型(Color Model)。
RGB, HSB, CMY, CIE XYZ, CIELAB，CMYK 和颜色的光谱描述方法都是颜色模型
编目系统(Cataloging System)。
Munsell 颜色系统，Pantone 公司开发的Pantone 颜色系统都是属于编目系统。
颜色空间是颜色模型最普通的例子。

颜色空间通常用三维模型表示，空间中的颜色能够看到或者使用颜色模型产生。
颜色空间有设备相关和设备无关之分。

CIE色度图

(CIE Chromaticity Diagram)就是用平面表示的马蹄形曲线，它为大多数定量的颜色度量方法奠定了基础。色调、饱和度、明度。



颜色空间变换：了解。``

B301 多媒体技术-基础理论技术-视频及其应用

视频的扫描线

720P，1080P？画面清晰度是以水平清晰度作为单位。清晰度的单位是"电视行(TVLine)"也称线。



彩色电视中的彩色空间变换

用RGB彩色空间表示的彩色信号需经过变换电路转换到一个亮度信号Y和二个色差信号C1、C2的彩色空间，再进行调制，然后进行传输。

C1、C2的含义与具体应用有关:

• PAL中，C1、C2表示U、V；NTSC中C1、C2表示I、Q。

• 不同的彩色空间在不同的应用中也许会比原始的RGB彩色空间具有更有用的特性。

彩色电视中使用Y、C1、C2彩色空间的优点:
(1) Y 和C1、C2独立，使得黑白电视和彩色电视都可以接收彩色电视信号，并且黑白电视机可以直接使用亮度信号Y;
(2)利用人眼对亮度较为敏感，而对色度相对不够敏感的特性，来节省信号的带宽和功率。色差信号使用的采样频率比对亮度信号使用的采样频率低。

■ 彩色空间之间的转换

- 用8位二进制数表示BT.601的Y'CbCr和R'G'B'，而R'G'B'颜色空间使用相同数值范围[0, 219]的分量信号，R'G'B'和Y'CbCr两个彩色空间之间的转换关系用下式表示:

$$
\begin{aligned}
Y &= 0.299R + 0.587G + 0.114B + 16 \\
Cr &= (0.500R - 0.4187G - 0.0813B) + 128 \\
Cb &= (-0.1687R - 0.3313G + 0.500B) + 128
\end{aligned}
$$

图像子采样定义和理论依据:

对色差信号使用的采样频率比对亮度信号使用的采样频率低的采样称为图像子采样。

图像子采样的理论依据与用途:
1、人的视觉系统的特点(图象子采样的理论依据):
• 人眼对色度信号的敏感程度比对亮度信号敏感的程度低;
• 人眼对图像细节的分辨能力有限，取掉一些高频信号后人眼不易察觉。
2、图像子采样的用途:
• 根据人的视觉系统的特点，可以通过图像子采样实现彩色电视图像数据的压缩。

视频编码核心思想就是去除冗余信息:
空间冗余
• 图像相邻像素之间有较强的相关性

时间冗余
• 视频序列的相邻图像之间内容相似
编码冗余
• 不同像素值出现的概率不同
视觉冗余
• 人的视觉系统对某些细节不敏感
知识冗余
• 规律性的结构可由先验知识和背景知识得到

MPEG Video的数据压缩依据和方法:

数据压缩的依据
时间冗余、空间冗余、结构冗余、视觉冗余等多种冗余信息。
通过消除这些冗余就可以实现图像数据的压缩。

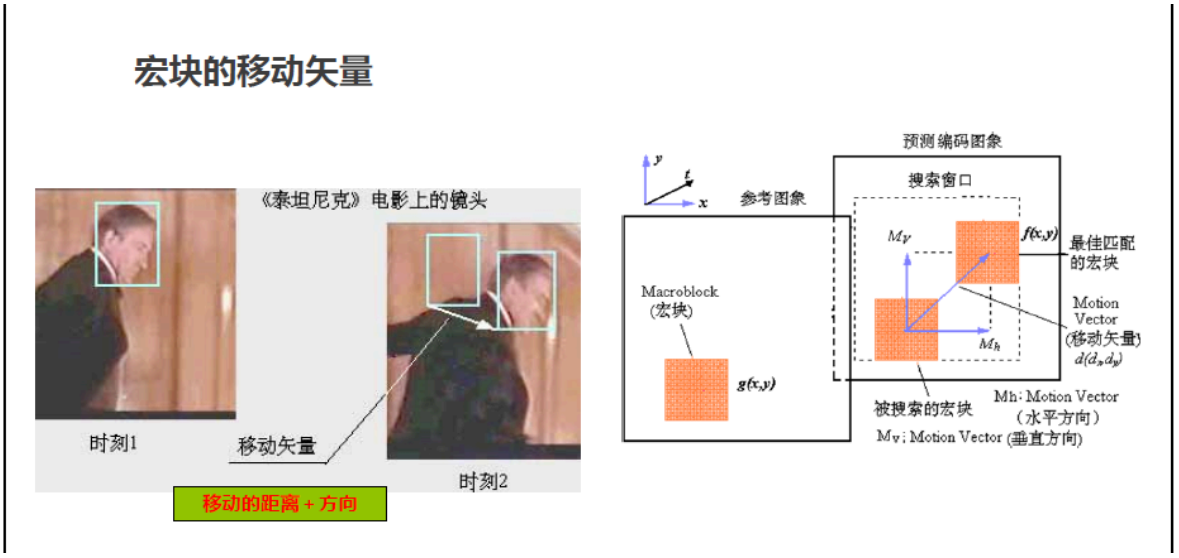
基本思想和方法要点:
在空间方面：对单帧图像数据，采用JPEG压缩算法来去掉帧内的冗余信息;
在时间方面：对连续的多帧图像数据，采用移动补偿算法来去掉帧间的冗余信息。

三种图像(采用不同的方法)
帧内图(Intra Pictures I),
预测图(Predicted Pictures P)
插补图(Bidirectional Prediction B) 即双向预测图

1.内帧(I)：采用JPEG算法进行中等程度的压缩压缩；
内帧压缩算法在编码解码时不依赖其它任何帧，可作为随机访问点。

2.预测帧(P)：以前面的参照帧(I或P)为基础进行预测编码和运动补偿法压缩存储，它本身又可作为后面预测帧的参照帧。编码与JPEG类似。以图像宏块为基本编码单元，一个宏块定义为I×J像素的图像块。以图像宏块为基本编码单元，一般16×16。

对P图像的压缩编码，两种类型的参数：1)当前要编码的图像宏块与参考图像的宏块之间的差值
2)宏块的运动矢量



寻找最佳宏块的三种简化算法：

对预测帧的编码：
 寻找最佳匹配图像宏块
 找到最佳移动矢量d(dx , dy)

主要算法：
 1)二维对数搜索法(2D - Logarithmic Search)
 2)三步搜索法(Three-step Search)
 3)对偶搜索法(Conjugate Search)

3.双向预测帧(B)

定义
 双向预测帧又叫内插帧
 需要前后两个参照帧：
• 采用双向预测编码和运动补偿法来进行图像编码
• 本身不能作为参照帧，只是I和P之间的内插帧

压缩比最高。

MEMC运动补偿。检测特定帧中的运动，并尝试估计后续帧的外观，并通过添加相关帧进行补偿。

大多数现代电影都以24fps的标准帧速率拍摄。
– 在具有60 / 120Hz显示屏的电视或智能手机上观看时，这部电影会显得抖动。
– MEMC所做的是尝试预测下一帧的外观并将其添加到连续的帧之间，以弥补
帧不足的问题。

传统插帧方法优劣势一览

视频帧率
视频帧率（简称P）指的视频每秒钟播放的图片数目

快门速度指每张图片曝光时间的长短，也就是每一帧快门保持打开的持续时间.
如果你选择拍摄60P帧率的视频时，快门速度选择30分之一秒的话，拍出来每秒最多得到30张单独的图像，另外30张是根据前面30张复制过来的。

拍摄时要注意的是，你的快门速度一定要比帧率高。一般快门速度都是设定在比帧率倒数快一倍的档位上，如25P帧率使用1/50秒快门。

视频处理的一些应用：

视频清晰增强

视频直播技术：视频+“交互”

视频分割：视频物体分割。从视频所有图像中把感兴趣的物体区域完整地分割出来。

视频产生新的应用入口：“视频+交互”成网络视频新机遇。

深度造假（deepfaking）：DeepFaceLab

视频与三维数据：SLAM(simultaneous localization and mapping)全称即时定位与地图构建或并发建图与定位，它主要的作用就是让机器人在未知的环境中，完成定位（Localization），建图(Mapping)和路径规划(Navigation)。

追求视觉智能

看图作文：进一步理解视觉信息：用推理来完善描述

习题：

1. 世界上主要的彩色制式是哪几种？

世界上主要的彩色电视制式有三种：

1. **NTSC 制式**：主要用于美国、日本等地区；
2. **PAL 制式**：主要用于中国、英国、德国等地区；
3. **SECAM 制式**：主要用于法国、俄罗斯等地区。

---

2. 电视机和计算机的显示器使用什么扫描方式？

传统电视机多采用**隔行扫描**，计算机显示器一般采用**逐行扫描**。

隔行扫描是把一帧图像分成奇数场和偶数场分别扫描，优点是节省带宽、运动画面较流畅，但可能产生闪烁和扭曲。逐行扫描是按顺序逐行显示整帧图像，画面更清晰稳定。课件也把 i 和 P 分别对应隔行扫描和逐行扫描。

3. ITU-R BT.601 标准规定 PAL 和 NTSC 的每一条扫描线的有效显示像素是多少？

BT.601 中，PAL 和 NTSC 数字视频每一条有效扫描线的**有效亮度采样点数都是 720 个**。

所以：

制式	每行有效显示像素
PAL	720
NTSC	720

但垂直方向不同：

制式	常见有效行数
PAL	576 行
NTSC	480 行

所以常见数字视频尺寸是：

- PAL：**720 × 576**
- NTSC：**720 × 480**

课件中也提到 BT.601 下的 YCbCr 颜色空间，并给出了 BT.601 的颜色变换关系。

---

4. 对彩色图像进行子采样的理论依据是什么?

理论依据是：**人眼对亮度信号更敏感，对色度信号不那么敏感。**

彩色视频通常把 RGB 转换为一个亮度信号 Y 和两个色差信号 C1、C2。这样既可以兼容黑白电视，又可以利用人眼对亮度更敏感、对色度较不敏感的特点，降低色差信号的采样频率，从而节省带宽和存储空间。

---

5. 一幅 YUV 彩色图像分辨率为 720×576，分别计算采用 4:2:2、4:1:1 子采样格式时的样本数。

先算总像素数：

```
720 × 576 = 414720 个像素
```

YUV 图像中，每个像素都有一个 Y 亮度样本，所以：

```
Y 样本数 = 414720
```

1）4:2:2 子采样

4:2:2 的意思是：

> 每 4 个 Y 样本，对应 2 个 U 样本、2 个 V 样本。

所以：

```
Y = 720 × 576 = 414720
U = 720/2 × 576 = 207360
V = 720/2 × 576 = 207360
```

总样本数：

```
414720 + 207360 + 207360 = 829440
```

所以：

> 4:2:2 的总样本数是 **829440 个样本**。

如果每个样本 8 bit，则存储量约为：

```
829440 字节
```

2）4:1:1 子采样

4:1:1 的意思是：

> 每 4 个 Y 样本，对应 1 个 U 样本、1 个 V 样本。

所以：

```
Y = 720 × 576 = 414720
U = 720/4 × 576 = 103680
V = 720/4 × 576 = 103680
```

总样本数：

```
414720 + 103680 + 103680 = 622080
```

所以：

> 4:1:1 的总样本数是 **622080 个样本**。

如果每个样本 8 bit，则存储量约为：

```
622080 字节
```

6. 视频图像数据压缩的依据是什么？

视频图像数据压缩的依据是视频中存在大量冗余信息，主要包括：

1. **时间冗余**：相邻帧之间内容变化不大；
2. **空间冗余**：同一帧中相邻像素往往相似；
3. **结构冗余**：图像内容存在规律性结构；
4. **视觉冗余**：人眼对某些颜色和细节不敏感。

通过去除这些冗余，就可以实现视频压缩。课件中明确写到数据压缩依据包括时间冗余、空间冗余、结构冗余、视觉冗余等。

7. 视频图像的空间分辨率和时间分辨率是什么意思？

空间分辨率指一帧图像在空间上的像素数量，也就是图像的宽和高。时间分辨率指视频在时间上的采样密度，通常用**帧率 fps**表示。

B302 多媒体技术-基础理论技术-视频-视频编码

MPEG 是什么

MPEG 是 Moving Picture Experts Group，即活动图像专家组，由 ISO 和 IEC 联合成立，负责制定电视图像、声音数据的编码、解码和同步标准。MPEG 开发的标准称为 MPEG 标准。

MPEG 视频层次结构

从大到小：

```
Video Sequence 视频序列
→ GOP 画面组
→ Picture 图像/帧
→ Slice 片
→ Macroblock 宏块
→ Block 块
```

其中 Slice 是出现通道错误时中断解压缩后重新同步的最小单元。

运动图像压缩的基本思想

运动图像压缩主要基于两点：

1. 运动图像序列中存在大量重复数据，可以用数学方法表示重复部分，从而减少数据量；
2. 人眼对图像细节和颜色的辨认有极限，超过感知极限的信息可以去掉。

对应两类压缩：

依据	类型
去除重复数据	无损压缩
去除人眼不敏感信息	有损压缩

实际视频压缩通常是有损和无损结合。

基本方法主要表现：
1）在空间方向上（静态图像）
• 图像数据压缩采用JPEG（Joint PhotographicExperts Group）压缩算法来去掉冗余信息。
2）在时间方向上（图像变化）
• 图像数据压缩采用移动补偿（Motion Compensation）算法来去掉冗余信息。

H.264 与 H.265 对比

H.264 / AVC

H.264 又称 AVC，高级视频编码，MPEG-4 Part 10。开源实现包括 openh264、x264。

特点：

- 兼容性好；

- 播放、剪辑相对容易；
- 文件体积比 H.265 大。

H.265 / HEVC

H.265 又称 HEVC，高效率视频编码，是 H.264 的继任者，开源实现包括 libde265、x265。

特点：

- 压缩效率更高；
- 同等画质下文件更小；
- 支持 4K、8K 等超高清视频；
- 编码和解码复杂度更高，对硬件要求更高。

H.265 的 CU、PU、TU

课件提到 H.265 中的：

- Coding Unit，编码单元 CU；
- Predict Unit，预测单元 PU；
- Transform Unit，变换单元 TU。

理解方式：

单元	作用
CU	决定这一块怎么编码，是编码基本组织单元
PU	决定如何预测，如帧内预测或帧间预测
TU	决定残差如何变换和量化

H.265 相比 H.264 更灵活。H.264 常用宏块，而 H.265 使用更大的 CTU，并可按图像复杂程度自适应划分。平坦区域用大块，复杂区域用小块，从而提高压缩效率。

Smart265

Smart265 是基于 H.265/HEVC 的编码优化技术，主要应用于监控领域。它通过智能调整码率，在保持画质前提下节省存储空间和带宽。

CBR 与 VBR

类型	含义	特点
CBR 固定码率	不管画面变化大小都用固定码率	画质稳定但空间占用大
VBR 动态码率	根据画面变化调整码率	静态画面少编码，动态区域多编码，更省空间

Smart265 适合长时间监控、夜间监控、存储成本敏感场景。但缺点是夜晚亮点、摄像机轻微晃动等可能被误判为前景，导致画面分离异常。

MPEG标准列表

当下视频数据的多维度属性

B303 多媒体技术-基础理论技术-视频-常见的音视频接口

接口总体分类

可以按信号类型记：

类型	接口
模拟接口	AV、S 端子、色差分量、VGA
数字接口	DVI-D、HDMI、DP、USB-C、Thunderbolt
混合接口	DVI-I 可兼容数字和模拟

常见接口分辨率

课件给出接口分辨率参考：

接口	典型分辨率
AV 接口	340×288，576P
S 端子	640×480，576P
色差分量	1280×720，1080P
VGA	1920×1080，1080P

AV 最低，S 端子稍好，色差分量可到高清，VGA 可支持 1080P，HDMI/DP 更适合高清和超高清数字传输。

RCA / AV / 色差分量

RCA

RCA 是莲花插座，不是专门某一种信号接口。它既可以传音频，也可以传普通视频，还可以作为 DVD 分量 YCrCb 的插座。

AV 接口

常见黄白红三根线：

- 黄：视频；
- 白、红：左右声道音频。

特点：

- 模拟信号；
- 画质较低；

- 老电视、老 DVD、机顶盒常见。

色差分量

通常是 Y、Pb、Pr 三路视频信号，画质高于 AV。

特点：

- 模拟分量视频；
- 可支持更高分辨率；
- 要注意电视信号源切换到“分量”。

---

4. DVI

DVI 全称 Digital Visual Interface，是数字视频接口，基于 TMDS 技术传输数字信号。课件中说明 TMDS 会将 RGB 每路 8bit 数据转换为 10bit 数据，并包含同步、时钟、纠错等信息，再用差分信号传输。

DVI 类型：

类型	特点
DVI-D	纯数字，只能接收数字信号
DVI-I	数字 + 模拟，可通过转接头兼容 VGA

> 为什么 DVI-I 可以转 VGA，而 DVI-D 不行?

答：DVI-I 同时包含模拟和数字信号引脚，可输出模拟信号；DVI-D 是纯数字接口，不兼容 VGA 的模拟信号。

---

5. HDMI

HDMI 是 High Definition Multimedia Interface，即高清晰度多媒体接口。它能同时传输数字视频和数字音频。

常见类型：

类型	使用场景
标准 HDMI	电视、显示器、机顶盒、电脑
Mini HDMI	平板、相机等
Micro HDMI	手机、便携设备等

HDMI ARC

ARC 全称 Audio Return Channel，即音频回传通道，主要用于音频回传。比如电视通过 HDMI ARC 把声音回传到功放或音响。

一句话记：

> ARC 解决的是“电视声音怎么回到音响”的问题。

HDMI CEC

CEC 可以让一个遥控器控制多个支持 CEC 的 HDMI 设备。比如电视遥控器控制播放器、功放等。

一句话记：

> CEC 解决的是“多个设备能不能统一遥控”的问题。

HDMI HEC

HDMI 1.4 引入 HEC，让 HDMI 线可以传输网络信号。

一句话记：

> HEC 解决的是“HDMI 能不能顺便传网络”的问题。

---

6. DP、Thunderbolt、USB-C

DP

DP 即 DisplayPort，是数字视频接口。课件中提到 HDMI 采用 TMDS 传输方式，而 DP 采用微图像传输。

特点：

- 常见于电脑显示器；
- 高带宽；
- 适合高分辨率、高刷新率显示。

Thunderbolt

课件表格中提到 Thunderbolt 4.0 属于数字接口，带宽可达 40Gb/s。

接口带宽趋势

课件表中给出的趋势：

接口	信号类型	典型支持
VGA	模拟	1080P
DVI	数字	2K
HDMI 2.1	数字	8K，48Gbps
DisplayPort 2.0	数字	16K，80Gbps
Thunderbolt 4.0	数字	40Gb/s

记忆重点：

> 现代高清、超高清显示主要依赖 HDMI、DP、Thunderbolt、USB-C 等数字接口，传统 AV、VGA 已逐渐淘汰。

---

7. CMMB 与 IPTV

CMMB

CMMB 是 China Mobile Multimedia Broadcasting，中国移动多媒体广播，是面向手机、PDA、MP3、MP4、数码相机、笔记本等移动终端的多媒体广播系统。

IPTV

IPTV 是基于 IP 网络传输电视业务。它和传统广播电视不同，依赖网络传输，可实现点播、交互等功能。

B304 多媒体技术-基础理论技术-视频各领域研究情况

1. 视觉语言模型 VLMs

视觉语言模型处于计算机视觉和自然语言处理交叉领域，如 LLaVA、Qwen-VL-Max 等，可以理解图像，并生成描述或回答图像相关问题。

应用：

- 视障辅助：生成图像描述，帮助理解周围环境；
- 电商搜索：用户可用图像 + 文本查找商品；
- 客服：聊天机器人理解用户上传图片并回答问题。

挑战：

- 需要大规模、高质量的图文数据；
- 未来可能与 AR、VR 融合，增强沉浸式交互。

---

2. NeRF 神经辐射场

NeRF 可以仅凭多张 2D 图像，通过预测空间中光线颜色和密度，重建逼真的 3D 场景。

应用：

- VR / AR 场景重建；
- 游戏、电影、沉浸式体验；
- 房地产 3D 看房；
- 文物和历史遗迹数字化存档。

挑战：

- 计算量大；
- 实时性不足；
- 未来方向是更高效、更实时的三维重建。

---

3. 扩散模型

扩散模型先向数据中逐步加入噪声，再学习去噪，从而生成图像。

应用：

- AIGC 内容创作；
- 艺术设计；
- 医学图像增强和重建；
- 未来可扩展到视频生成。

挑战：

- 训练和推理成本高；
- 需要反复去噪；
- 视频生成中还要保持时间一致性。

---

4. 少样本学习与零样本学习

少样本学习：只用少量样本学习新类别。
零样本学习：没有该类别训练样本，也能根据语义知识识别新类别。

应用：

- 医学罕见病识别；
- 标注成本高的场景；
- 动态环境中的新类别适应。

挑战：

- 泛化能力难保证；
- 很少样本下容易过拟合；
- 未来方向是迁移学习、强化学习等结合。

---

5. 掩码自编码器 MAE

掩码自编码器通过遮挡图像的一部分，让模型学习恢复缺失内容，从而获得视觉表征。

应用：

- 自监督视觉预训练；
- 视觉 Transformer 预训练；
- 医学图像等标注不足场景。

挑战：

- 掩码比例需要平衡；
- 掩码太多，输入难以识别；
- 掩码太少，学习难度不足。

---

6. GAN 生成对抗网络

GAN 由生成器和判别器组成：生成器生成假数据，判别器判断真假，两者对抗训练，最终生成高质量合成数据。

应用：

- 图像生成；
- 图像增强；
- 超分辨率；
- 黑白图像上色；
- 隐私敏感场景下生成合成数据。

挑战：

- 训练不稳定；
- 容易模式崩溃；
- 对超参数敏感。

---

7. 对比学习

对比学习是一种自监督学习方法，通过构造正负样本对，让模型学习区分相似和不相似样本。

应用：

- 图像分类；
- 目标检测；
- 人脸识别；
- 视觉表征学习。

挑战：

- 正负样本对质量很关键；
- 错误构造样本会影响表示学习；
- 未来方向是自动选择更有效的对比样本。

---

8. GNN 图神经网络

GNN 适合处理图结构数据。在计算机视觉中，可以建模图像区域、物体之间的关系，用于场景理解。

应用：

- 交通场景分析；
- 行人、车辆、基础设施关系建模；
- 社交网络分析；
- 图像中物体关系理解。

挑战：

- 图结构构建复杂；
- 计算量较大；
- 可扩展性问题突出。

---

9. Visual SLAM

Visual SLAM 即视觉同时定位与地图构建。系统一边估计自身位置，一边构建环境地图。

应用：

- 自动驾驶；
- 无人机；
- 配送机器人；

- AR 中数字物体锚定到真实空间。

挑战：

- 计算成本高；
- 动态环境中表现不稳定；
- 光照差时效果下降；
- 未来方向是轻量级、鲁棒性更强的 SLAM。

---

10. XAI 可解释人工智能

XAI 关注模型为什么做出某个判断，尤其在医学和自动驾驶等高风险场景中很重要。

应用：

- 医学影像诊断解释；
- 自动驾驶决策解释；
- 提升模型可信度和安全性。

挑战：

- 可解释性和性能之间存在平衡；
- 深度模型复杂，难以直观解释；
- 未来方向是在不明显降低准确率的情况下提升透明度。

---

11. 视频物体分割 VOS

视频物体分割 Video Object Segmentation，简称 VOS，指从视频所有帧中把感兴趣的物体区域完整分割出来。

三个方向：

1. 半监督视频物体分割；
2. 交互式视频物体分割；
3. 构建完整计算机视觉处理流程来理解视频。

可以这样答：

> 视频物体分割不仅要识别单帧中的物体，还要在连续帧中保持目标区域的一致性，因此比静态图像分割更强调时序稳定性、目标跟踪和遮挡处理。

---

12. 人体解析、手势识别、运动分析

人体解析是以人为中心的视觉理解任务，目标是对图像或视频中的人体部位、服装、配饰等进行像素级分类。

手势识别 Hand Pose 用于识别人手姿态，可用于人机交互、AR/VR、手语识别等。

人体运动分析可以用于评估运动障碍患者，帮助医生制定手术计划和评估治疗效果。

---

13. 三维数据：感知、表示、理解

课件把三维数据的计算机视觉方法概括为三个挑战：

```
感知 → 表示 → 理解
```

感知

获取三维数据较复杂，二维摄像头便宜普遍，但三维感知常需要专用硬件。

常见方式：

方式	原理	特点
立体视觉 Stereo	多个摄像头匹配像素差异，计算深度	成本较低，但依赖匹配效果
RGB-D	同时获取 RGB 图像和深度信息	Kinect、FaceID 等使用
激光雷达 LiDAR	发射激光并测量返回时间	精度高、距离远，但贵且设备大

课件还提到 RGB-D 可能存在孔洞，原因包括遮挡、模式感知失败、感知范围限制；激光雷达准确性和鲁棒性强，但传统设备昂贵，行业尝试发展固态激光雷达。

---

14. 音视频采集与互动直播

音频采集

音频采集过程：设备采集环境模拟信号，转换为 PCM 原始数据，再压缩成 MP3 等格式分发。常见音频压缩格式包括 MP3、AAC、OGG、WMA、Opus、FLAC、APE、m4a、AMR 等。

音频采集关键参数：

- 采样率；
- 位宽；
- 声道数；
- 音频帧。

课件强调音频本身没有天然“一帧帧”的概念，实际处理中常把 2.5ms 到 60ms 的数据量约定为一帧音频。

图像采集

图像采集过程：摄像头拍摄成 YUV 编码的原始数据，再编码压缩成 H.264 等格式分发。常见视频封装格式包括 MP4、3GP、AVI、MKV、WMV、MPG、VOB、FLV、SWF、MOV、RMVB、WebM 等。

图像采集关键参数：

- 图像传输格式；
- 图像格式；
- 传输通道；
- 分辨率；
- 采样频率。

互动直播技术难点

课件提到三大难点：

1. **低延迟互动**：主播和互动观众要像电话一样实时交流；
2. **音画同步**：音频和视频要在低延迟条件下同步；
3. **音视频实时合成**：其他观众需要实时看到互动结果，需要客户端或服务端实时合成。

关键词：

> RTC = Real-time Communications，实时通信；WebRTC 是网页实时音视频通信的重要技术。

C101 交互理论-交互的介绍

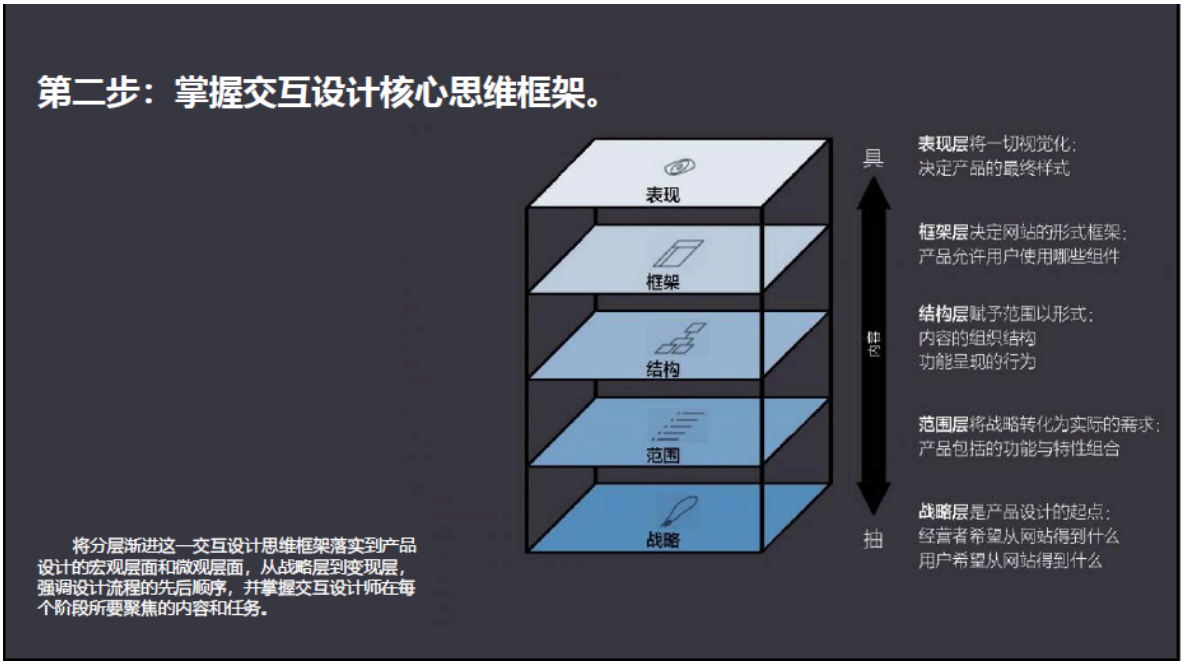
交互的基本概念、学习方法（软件设计）、技能等。

如何学习交互设计：

第一步：从感性设计转变为理性设计。对于交互设计而言，在处理需求时，需要强化逻辑思维、理性思维，减少直觉思维和感性思维。

第二步：掌握交互设计核心思维框架：

分层渐进设计法的理论：





新产品和新技术：

RFID物体识别互动桌 多点触摸屏，展览展示，多媒体互动设备，电容识别感应交互系统，展厅设计

人工智能技术：语音界面

VR和AR

没有界面的界面

交互是多个学科综合：

交互位于：设计；产品；技术；三者交叉处。

软能力和硬能力

HCI 有两个含义

1. Human-Computer Interaction
    - 人机交互；
    - 研究设计、评价和实现供人使用的交互计算系统。
2. Human-Computer Interface
    - 人机界面；
    - 人与计算机之间传递、交换信息的媒介和对话接口。

类型	含义
硬交互	实体产品 = 人机工学 + 体验设计
软交互	虚体界面 = UI

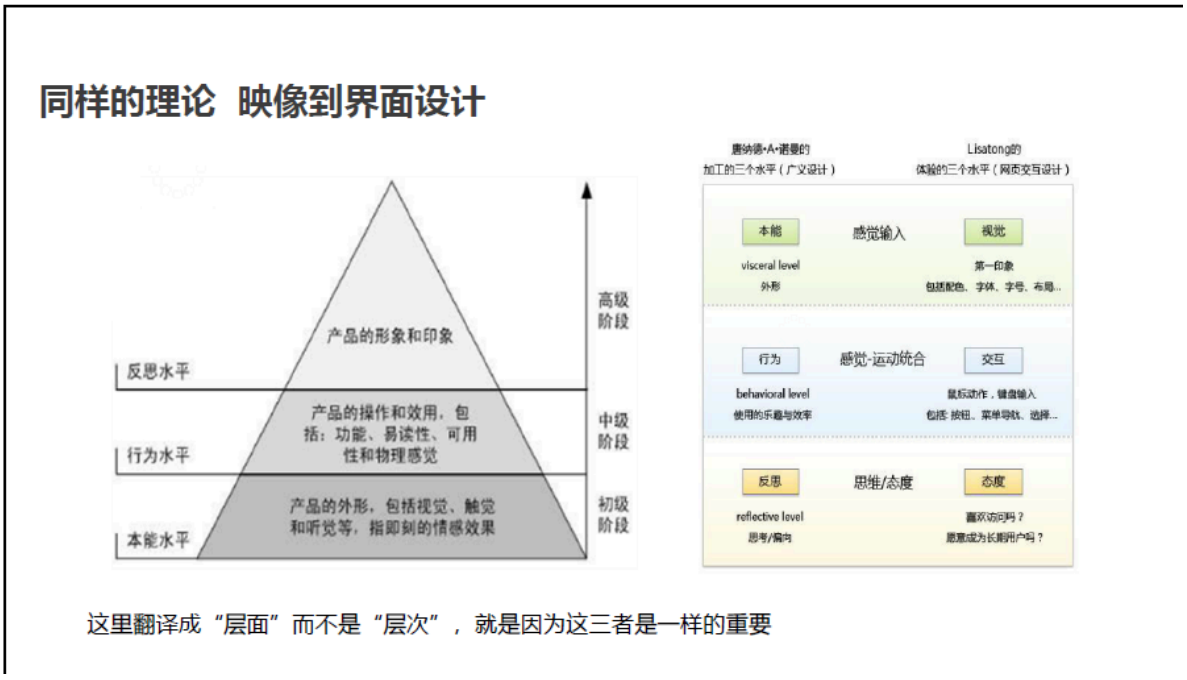
什么是交互设计?

交互设计，又称互动设计，(英文Interaction Design, 缩写IxD 或者IaD) 。设计人造系统的行为的设计领域。人造物，即人工制成物品，例如，软件、移动设备、人造环境、服务、可佩带装置以及系统的组织结构。交互设计在于定义人造物的行为方式(the "interaction",即人工制品在特定场景下的反应方式)相关的界面。

交互设计的三要素

用户
– 交互设计的服务对象是用户，我们根据用户来指定相对应的交互流程和界面。
• 需求
– 交互设计是承接产品经理的工作的，产品经理会提供一系列的需求。
• 场景
– 有了用户，有了需求，接下来就是要设想用户的使用场景。

交互设计与产品设计有着一样的设计流程与方法
交互设计侧重于设计层面中的第二层：行为设计



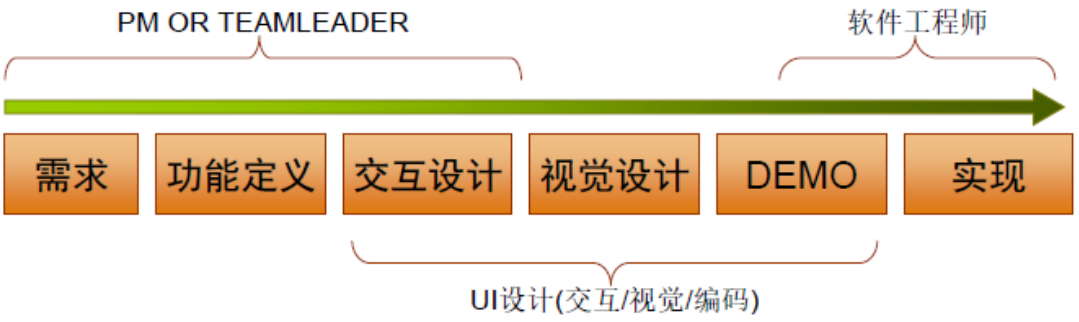
这里翻译成“层面”而不是“层次”，就是因为这三者是一样的重要

分层渐进设计法的理论

常用的设计模型:



UI设计:



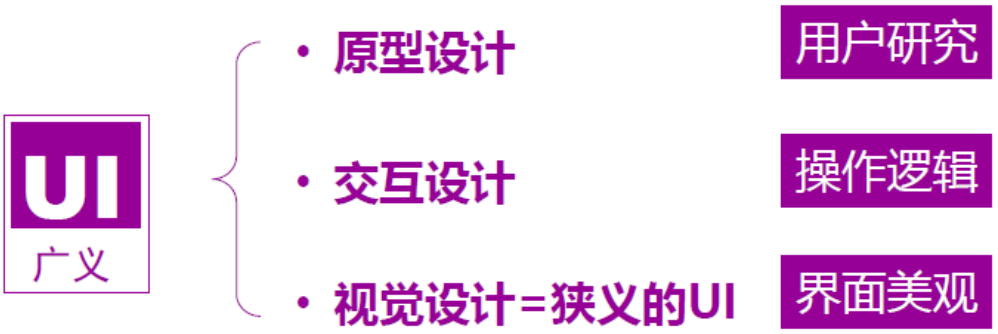
交互设计生成产品原型-线框图

视觉设计生成产品模型-效果图

CSS/HTML-生成产品DEMO

编码-实现产品

UI设计则是指对软件的人机交互，作逻辑，界面美观的整体设计。



UI设计三个方向：

1. 研究人：用户研究，得出定位与原型。以人为本 UI设计，必须研究人，研究我们的用户，要了解我们的用户想要什么，要利用我们的产品解决什么问题，喜欢什么，不喜欢什么等等。
   用户研究工程师一般是心理学人文学背景。
2. 研究人与界面的关系：交互设计：研究 操作逻辑（理性） 与 体验（感性）。即人机交互，研究如何让用户更好的更方便的使用软件，则是我们常说的“易用性”。从事该行业的人，称之为“**交互设计师**”，主要做的工作内容就是设计软件的操作流程，树状结构，软件的结构与操作规范等。一个软件产品在编码之前需要作的就是交互设计，并确立交互模型，交互规范。
3. 研究界面：研究用户审美与习惯。
4. 从事该行业的人，我们可以称之为:**软件图形设计师**，其中大部分是有美术设计教育背景，例如视觉传达设计，工业设计，信息多媒体设计等。

   UI 设计涉及领域：
   - 设计心理学；
   - 情感化设计；
   - 视觉设计；
   - 美术原理知识。

UX：用户体验

用户体验包含了终端用户与一个企业. 它的服务以及它的产品交互的所有方面。UX 是终端用户与一个产品或服务互动感知的全体。

UX->UED
用户体验->用户体验设计

UI 设计案例：人性化按钮设计

讲“人性化 UI 按钮设计”，提出 8 条原则：

1. 用户界面应该基于用户心理，而非工程实现；
2. 尽可能少让用户输入，输入时给出参考；
3. 对用户输入结果进行保存；
4. 提供非模态反馈，不打断任务流；

5. 全局导航必须一直存在；
6. 不要让用户等待任务，合理利用碎片时间；
7. 为了程序响应速度，需要进行掩护设计；
8. 培养以用户使用情景为思维去做设计。

C102 交互理论-软件开发过程中的UI和UE原则与设计案例

1. UI设计师需要做到什么?

   简易性：
   界面的简洁是要让用户便于使用，便于了解并能减少用户发生错误选择的可能性。——提高用户的熟悉程度： 用户可通过已掌握的知识来使用界面，
   但不应超出一般常识。

   可控性：
   这是界面设计的先决条件，用户想要做什么，就一定让他做到，并且必须得到应有的提示。
   记忆负担最小化：
   人脑比不了电脑，人类的短期记忆极不稳定有限。不要轻易打破用户的行为习惯，不要让用户思考。
   一致性：
   每一个优秀界面都具备的特点。
   界面的结构必须清晰且一致，风格必须与实际内容相一致。
   同一软件的不同界面，同一界面的不同板块，同一板块的不同位置，都必须保持相当的一致性。
   ——有序排列

   安全性：
   – 用户能自由的作出选择，且所有选择都是可逆的。
   – 在用户作出危险的选择时有信息介入系统的提示。

   灵活人性化：
   – 高效率和用户满意度是人性化的直接体现。
   – 要尽可能考虑到特殊用户的操作体验，如色盲，残疾人等。

2. UI设计过程的几个要点/这些原则如何付诸行动?
   - 遵循用户的心理模式
   - 符合用户的使用需求
   - 一致性原则
   - Less is More
   - 使用用户的语言与之沟通
   - 设计目的性大于美观性
   - Don't make me think

     直觉化
   - 允许犯错原则
   - 信息反馈原则

3. 格式塔定律| 4个心理学小知识提升你的设计价值

   格式塔心理学是把人的思想和行为看成是一个整体的思想流派。

   1. 亲密性。当物体彼此靠近时，这些物体被看作是一个整体而不是独立的。

2. 相似性原则出现在物体看起来相似的时候，人们常常会把他们看作是一个组或者是一个模式。
3. 焦点是画面中用户感兴趣、强调或者差异的区域，能够抓住用户的注意力。

   古腾堡原则是由14世纪西方活字印刷术的发明人约翰·古腾堡提出，他
   认为人们在阅读的时候是遵循某种顺序的，那么有最重要的区域，也有次一级的区域，由此推演出了一张图片。

古腾堡图解定理



- 人们的视觉区域划分成了4块，从左到右，从上到下。
  - 1、第一视觉区(POA)：左上方，用户首先注意到的地方
  - 2、强休息区(SFA)：右上方，较少被注意到
  - 3、弱休息区(WFA)：左下方，最少被注意到
  - 4、终端视觉区(TA)：右下方，视觉最终停靠点

---

4. 共同区域的原则与亲密性原则很相关。它的意思是当物体在同一个封闭区域内时，会被认为是同一组元素。

C103 交互理论-交互设计7大定律

交互设计：交互设计师需要读懂的7大定律。

1. 费茨定律：费茨定律是人机交互和人体工程学中人类活动的模型，它预测了从任意位置快速移动到一个目标位置所需的时间由2个位置的距离(D)和目标大小(S)有关。

   距离(D)：
   – 既起始位置离目标位置距离越远，我们到达目标位置所花费的时间就越长。反之，离目标位置越近，我们所花费的时间就越短；
   目标大小(S)：
   – 即目标面积越大，我们定位到目标的所花费的时间就越短。反之，目标面
   积越小，精准定位到目标上的时间就越长。

   界面中的费茨定理：距离目标位置尽量缩短，相关操作保持亲密性。在PC端做后台表单设计时，把决策性按钮紧跟在表单下方，距离表单最近的位置，
   这也是为了缩短光标移动的距离，使操作项(要输入的表单)和决策项(提交/
   取消按钮)更具有关联性。

   在界面设计中，可以有意识的将一些操作放在死角处，既相对不容易点击到、感知到的地方，这就是为了延长用户的感知时间，感知时间长即操作完成时间长，操作成本也就越高，从而减少误操作的可能性。

   目标尺寸大小要合适。点击热区：拇指默认悬停的位置恰好在屏幕下方。

   鼠标光标，屏幕边角适合放菜单、按钮组和一些辅助性操作。

2. 米勒定律：人的短时记忆能力广度为7±2个信息块，记忆信息超过了该范围就容易出错。1)分段记忆，信息分层，把手机号码分为3-4-4的规则。还可以用于文章排版。2)导航和选项卡通常不要超过9个。3)系列位置效应。相对于中间，开头和结尾更容易记住。
3. 席克定律。用户所面临的选择数量越多，做出选择所花费的时间就越长，在人机交互的界面中选项越多，意味着用户做出决策的时间越长。设计时应该思考“在不妨碍用户选择的情况下，如何提供较少的选项”。

   全部的选项没必要平铺出来，选项与选项之间一定有着某种联系，所以也
   可以对选项进行同类分组和多层级分布。

   1)减少选项并提供默认值，方便用户选择。比如默认圆形当单选，方形当多选。

   2)选项分类分层，信息区分主次。

   3)分步完成，分步显示。分解复杂流程。场景细分。
4. 接近法则(亲密性)：通常把位置相对靠近的事物当成一个整体：接近法则的“权重”非常大，大到可以抵消其他法则。

   把相关的信息块组合在一起，不太相关的分离开，增强与区分元素之间的关联性，所强调的是空间和位置。界面设计中的接近原则是对相似的信息及功能类别进行分组、布局。留白(负空间)在界面中发挥着至关重要的作用，因为它能够引导用户眼睛的朝向，并且可以用于区分视觉层次，有助于提高阅读体验。
5. 泰斯勒定律(复杂性守恒定律)：该定律认为每一个过程都有其固有的复杂性，这个复杂性存在一个临界点，超过了这个点就不能再简化了，你只能将固有的复杂性从一个地方移动到另外一个地方。

   比如我们发现页面的功能是必须的，但当前的页面信息过载，那么就需要
   将次要的功能收起或者转移，但是你却无法删除他，只能想办法权衡。删除、组合、隐藏、转移、拆分，
6. 奥卡姆剃刀原理：如无必要，勿增实体，即简单有效原理

   a.优先展示重要功能 b.减少点击次数，给予合理的选项 c.“外婆”规则
   – 如果年龄大点的用户也能轻松的使用你的产品，说明产品的可用性和易学
   性非常强。
7. 新乡重夫：防错原则

   用户在界面中发生的错误大部分是由设计和开发过程中的疏忽造成的，而不能认为是用户操作疏忽。在设计中非常有必要考虑防错机制，尤其是用户的操作具有毁灭性效果的功能时要有强提示和强确认，防止用户犯不可挽回的
   错误。

   a.比如在录入长表单中
   前端与后端及时检测录入信息的有效性和正确性，而不是让用户填写完所
   有表单再点击提交按钮之后，再告诉用户哪一项录错了。

   b.经常无意间会输入错别字。

   用户的错误操作：（操作前）友好提醒：当结果不可逆时，询问用户
   让其知道操作的后果。适当限制用户的某些交互操作。

   （操作中）实施感知：对用户的操作进行视觉化呈现，并及时回馈。

   （操作后）及时反馈&友好引导：允许用户犯错，并支持操作可逆(既撤销以前的指令)。

原则	**你就记成**
费茨定律	**点不点得到、点得快不快**
米勒定律	**记不记得住、信息会不会太多**

原则	你就记成
希克定律	**选不选得出来、选择会不会太多**
接近法则	**看不看得出哪些是一组**
泰斯勒定律	**复杂度不能消失，只能转移**
奥卡姆剃刀	**没必要的东西就删掉**
防错原则	**别让用户犯错，犯错也能补救**

C201 交互技术-媒体输入与输出

交互界面的三个阶段：

阶段	名称	特点
第一阶段	CLI 命令行界面	通过键盘输入命令
第二阶段	GUI 图形用户界面	通过鼠标点击图形界面
第三阶段	NUI 自然用户界面	通过语音、触摸、手势等自然方式交互

> NUI = 更自然、更符合人类习惯的交互方式。

例如：

- Siri 语音交互；
- 触摸交互；
- 手势交互；
- 人脸识别；
- VR / AR 交互。

人机交互时代变化

时代	设备	交互方式
DOS 时代	键盘	命令行
PC 时代	鼠标	点击
移动互联网	手指	触摸
人工智能	手指 + 声音	对话

媒体输入 / 输出涉及的技术

- 媒体变换技术；
- 生物识别技术；
- 媒体理解技术；
- 综合技术。

生物特征分为：生理特征

例如：指纹；人脸；虹膜；掌纹；掌静脉；DNA 等。

行为特征

例如：步态；签名；声音；键盘敲击习惯等。

语音识别与语音交互：

Siri；Alexa；Google Home；Amazon Echo。语音交互是自然用户界面的典型形式，但其成熟依赖机器学习和用户数据。

指纹识别与掌纹 / 掌静脉识别：

虹膜识别：

人脸识别：

案例 1：防止司机犯困

“疲劳检测 & 驾驶行为识别预警系统”。

案例 2：FaceID

> FaceID，活体鉴别。

案例3：刷脸支付

人脸识别难题

步态识别——健身姿态纠正

大脑 脑机接口进行控制、交流、存取

虚拟现实技术：

C202 交互技术-交互形式与技术

人机交互技术(HCIT)是通过计算机输入和输出设备,以有效的方式实现人与计算机对话的技术。
一、交互的技术

- VR / AR；
- 触摸板；
- 声音交互；

  优点：
  – 降低用户的学习成本。
  – 反正都是对话框，啥都可以往里装，用户不管用什么功能，只要用一套交互方式。
  缺点：

– 效率低。
– 越是复杂的功能，用起来就越麻烦。

Quartz：对话式新闻APP。

适用场景和问题。

- 摄像头交互；
- 手势交互；摄像头，手势控制臂带Myo，超声波凌空触觉
- 眼镜交互；
- 触觉交互；
- 穿戴设备：手势、眼动、脑电；
- 位置感知等

二、新的交互技术的案例

人机交互基础理论包括：

1. 交互评价体系； 知觉组织原则与交互设计。
2. 交互认知机理；传统的用户信息处理模型围绕工作记忆、长时记忆、感知和运动系统来解释人处理信息的过程。刺激反应相容性与交互设计。
3. 可计算的交互模型；费兹定律(Fitts's law)是应用最广泛的人体运动控制模型，解释了指点空间目标时速度和精度之间的关系。
4. 交互情境感知。研究者开始融合各种简单情境信息，以推理人所处的活动、人的意图等具有更深层语义的情境。注意机制与交互设计。用户心理模型。

面向新型智能设备的交互技术

例如：

- 内置传感器——语音识别；
- 基于无线电信号；
- 基于声波感知；
- 振动感知；

物物相联的交互：地理围栏

大模型：

汇报

01 OpenClaw：一场技术热潮背后的冷思考

- OpenClaw（自托管 Agent 框架）、LLM（大语言模型）、API 接口集成 。
- **主要作用：** OpenClaw 是一个个人 AI 助手框架，支持将多个大模型（如 Deepseek、通义千问等）接入并部署在个人轻量级服务器上 。它可以通过飞书、微信等通讯工具下达指令，代替人工执行收发邮件、智能清理、定时任务等工作流（Workflow）自动化任务

02 数字人

- 2D/3D 数字人生成技术（如 Live2D、Wav2Lip、UE5 建模）与大语言模型对话系统。

- **主要作用：** 结合语音识别（ASR）、自然语言处理（NLP）和语音合成（TTS）以及口型同步技术，生成具有拟真外貌、能够与用户进行实时语音或文本交互的虚拟数字形象，常用于智能客服、虚拟主播等场景。

03 用双手演奏名画

- MediaPipe Hands（视觉手势识别）、Three.js / React Three Fiber（WebGL 渲染）、Web Audio API 。
- **主要作用：** MediaPipe 通过摄像头提取双手 21 个关键点以识别手势（如拨弦、击鼓）。Three.js 用于在浏览器端实现《星空》或《格尔尼卡》的动态视觉效果渲染 。Web Audio API 负责声音合成，三者结合形成零门槛、打开网页即用的手势音画交互艺术体验

03 文本转语音模型 Qwen3-TTS

- Qwen3-TTS（通义千问开源的语音生成模型）。
- **主要作用：** 一种基于深度学习的 Text-to-Speech (TTS) 技术，能够将输入的文本序列转化为自然、流畅且带有情感音色的音频输出，用于智能助手发声、有声书配音等。

04 从音源编曲到算法设计声音

- Sonic Pi（基于 Ruby 的实时编码音乐环境）、PCM 样本底层合成、OSC 协议 。
- **主要作用：** 区别于传统的 MIDI（发出乐谱指令驱动外部黑盒音源）和底层 PCM 合成（直接操作音频缓冲区，门槛极高），Sonic Pi 提供了一种通过编写代码（Ruby DSL）来实时生成和控制音乐的范式，既保留了乐谱逻辑的易用性，又拥有设计算法合成声音的灵活性 。

05 OpenCV

- OpenCV（开源计算机视觉库）。
- **主要作用：** 提供丰富的 C++ 与 Python 接口，用于处理传统计算机视觉任务，包括图像滤波、边缘检测、色彩空间转换、形态学操作以及基础的人脸/目标检测功能。

06 百度飞桨（PaddlePaddle）与 PaddleOCR 演示

- PaddlePaddle（深度学习框架）、PaddleOCR（光学字符识别）。
- **主要作用：** 飞桨是百度研发的国产深度学习平台。PaddleOCR 是基于该框架构建的开源文本识别系统，用于从各类图像、文档、票据中精准定位并提取文字内容。

07 AI 生成 PPT 工具与提示词优化实践

- AIGC 应用生成（如 Gamma、Tome 或 MindShow）、Prompt Engineering（提示词工程）。
- **主要作用：** 通过结构化、高信息密度的提示词（Prompt）引导大语言模型输出大纲，并结合自动排版引擎，一键生成带有版式和配图的演示文稿。

08 从 2D 像素到 3D 视界

- 2D to 3D 生成技术（如 NeRF、3D Gaussian Splatting、TripoSR 或生成式 3D 扩散模型）。
- **主要作用：** 将单张或多张二维平面图像，利用神经网络重建为其对应的三维几何模型（Mesh）或辐射场，用于游戏开发、虚拟现实和空间计算。

09 StableDiffusion1.5 使用汇报

- Stable Diffusion v1.5（潜在扩散模型 LDM）。
- **主要作用：** 开源文本到图像（Text-to-Image）生成模型。通过在潜空间（Latent Space）逐步去噪，实现根据提示词生成高质量图像、图生图（Img2Img）及局部重绘（Inpainting）等功能。

10 MediaPipe 的视觉手势识别与智能交互体验

- MediaPipe 框架（Google 开源跨平台机器学习管道）。
- **主要作用：** 在设备端提供轻量级、低延迟的视觉感知模型。专门用于追踪人体骨骼、面部网格和手部关键点，使得应用可以通过视觉获取用户的空间姿态并转换为交互控制信号。

11 NeRF 及其相关技术

- NeRF（Neural Radiance Fields，神经辐射场）。
- **主要作用：** 一种隐式三维场景表示方法。输入已知视角的 2D 照片集合，训练多层感知机（MLP）学习场景的体积密度和辐射亮度，从而能够合成该场景下任意新视角的逼真图像。

12 实时交互式 AI 绘画技术分享

- LCM（Latent Consistency Models，潜空间一致性模型）、LCM-LoRA 插件、Diffusers 。
- **主要作用：** 传统扩散模型生成单张图需经过数十步计算，耗时长且无法交互。LCM 将推理步数压缩至 1 到 4 步，将生成延迟降至 300 毫秒以内，结合前端画板，实现了“用户落笔、模型即时输出”的实时人机共创绘画体验 。

13 基于 TensorFlow.js 的实时视频背景模糊实现

- TensorFlow.js、BodyPix（轻量级人体分割模型）、WebRTC 。
- **主要作用：** 利用 WebRTC 获取摄像头视频帧，直接在前端浏览器中运行 TensorFlow.js 加载的 BodyPix 模型对当前帧进行实时语义分割。识别出人像并生成二值蒙版后，对背景应用高斯模糊，实现了低门槛、保护隐私的“零安装”虚化功能 。

15 足球比赛 AI 分析系统汇报

- CV 目标检测与追踪追踪（如 YOLO + DeepSORT）、人体姿态估计。
- **主要作用：** 处理足球比赛视频流，利用深度学习算法实时定位并追踪足球、球员与裁判的轨迹，计算跑动距离、控球时间、热力图及战术阵型等数据指标。

16 ShowUI：开源端到端 GUI 视觉-语言-动作模型

- VLA (Vision-Language-Action) 模型、GUI 自动化。
- **主要作用：** 赋能 AI 系统理解电脑屏幕（视觉）及用户的自然语言指令（语言），并直接推理出对应的操作坐标与键盘事件（动作），从而实现自动化控制图形用户界面（GUI）的能力。