一、简答题（共 50 分，每小题 10 分）

1. 请简述什么是假设空间，什么是版本空间。

答：假设空间是所有假设组成的集合（5 分）。
版本空间是与训练集一致的假设集合（5 分）。

2. 请简述训练误差、测试误差、泛化误差。训练误差小的时候，泛化误差就一定小吗？

答：学习器在训练集上的误差称为训练误差（3 分）。
学习器在测试集上的误差成为测试误差（3 分）
学习器在新样本上的误差成为泛化误差（3 分）。
训练误差较小的时候，泛化误差不一定小（1 分）。

3. 对数几率回归解决的是回归问题还是二分类问题？训练对数几率回归的方法是什么？

答：二分类问题（5 分）。
极大似然估计法（5 分）。

4. 朴素贝叶斯分类器解决了什么障碍？它的关键假设是什么？

答：朴素贝叶斯分类器解决了类条件概率是所有属性上的联合概率，难以从有限的训练样本直接估计而得的障碍（5 分）。
属性条件独立性假设（5 分）。

5. 请简述局部极小与全局极小。

答：局部极小是参数空间中的某个点，其邻域点的误差函数值均小于该点的函数值（5 分）。
全局极小是参数空间中所有点的误差函数值均小于该点的误差函数值（5 分）。

二、算法题（共 20 分，每小题 10 分）

1. 请为以下 k 均值算法的步骤 1，5，6，7，10 添加注释.

输入： 样本集 $D = \{\boldsymbol{x}_1, \boldsymbol{x}_2, \ldots, \boldsymbol{x}_m\}$;
聚类簇数 k.
过程：
1: $\{\boldsymbol{\mu}_1, \boldsymbol{\mu}_2, \ldots, \boldsymbol{\mu}_k\}$
2: **repeat**
3: 令 $C_i = \varnothing \ (1 \leqslant i \leqslant k)$
4: **for** $j = 1, 2, \ldots, m$ **do**
5: $d_{ji} = \|\boldsymbol{x}_j - \boldsymbol{\mu}_i\|_2$;
6: $\lambda_j = \arg\min_{i \in \{1,2,\ldots,k\}} d_{ji}$;
7: $C_{\lambda_j} = C_{\lambda_j} \cup \{\boldsymbol{x}_j\}$;
8: **end for**
9: **for** $i = 1, 2, \ldots, k$ **do**
10: $\boldsymbol{\mu}'_i = \frac{1}{|C_i|} \sum_{\boldsymbol{x} \in C_i} \boldsymbol{x}$;
11: **if** $\boldsymbol{\mu}'_i \neq \boldsymbol{\mu}_i$ **then**
12: 将当前均值向量 $\boldsymbol{\mu}_i$ 更新为 $\boldsymbol{\mu}'_i$
13: **else**
14: 保持当前均值向量不变
15: **end if**
16: **end for**
17: **until** 当前均值向量均未更新
输出： 簇划分 $\mathcal{C} = \{C_1, C_2, \ldots, C_k\}$

k 均值算法

答：
1：初始化均值向量（2 分）
5：计算样本$\mathbf{x}_j$与均值向量$\boldsymbol{\mu}_i$的距离 （2 分）
6：根据样本距离最近的均值向量确定$\mathbf{x}_j$的簇标记 （2 分）
7：将样本划入相应的簇 （2 分）
10：计算新均值向量 （2 分）

2. 请为以下决策树算法的步骤 3，6，8，12 添加伪代码。

输入： 训练集 $D = \{(\boldsymbol{x}_1, y_1), (\boldsymbol{x}_2, y_2), \ldots, (\boldsymbol{x}_m, y_m)\}$;
属性集 $A = \{a_1, a_2, \ldots, a_d\}$.
过程： 函数 TreeGenerate(D, A)
1: 生成结点 node;
2: **if** D 中样本全属于同一类别 C **then**
3:
4: **end if**
5: **if** $A = \varnothing$ **OR** D 中样本在 A 上取值相同 **then**
6:
7: **end if**
8:
9: **for** a_* 的每一个值 a_*^v **do**
10: 为 node 生成一个分支; 令 D_v 表示 D 中在 a_* 上取值为 a_*^v 的样本子集;
11: **if** D_v 为空 **then**
12:
13: **else**
14: 以 TreeGenerate(D_v, $A \setminus \{a_*\}$)为分支结点
15: **end if**
16: **end for**
输出： 以 node 为根结点的一棵决策树

决策树学习基本算法

答：
3：将 node 标记为 C 类叶节点；return （2 分）
6：将 node 标记为叶节点，其类别标记为 D 中样本数最多的类；return （3 分）
8：从 A 中选择最优划分属性a* （2 分）
12：将分支节点标记为叶节点，其类别标记为 D 中样本最多的类；return （3 分）

三、思考题（共 30 分，每小题 15 分）

1. 支持向量机基本型解决的是回归问题还是二分类问题？如果超平面不可以将训练样本正确分类，支持向量机基本型方法还可以用吗？如果不可以用，有哪些改进方法？这些改进方法的基本原理是什么？

答：

二分类问题（2 分）

不可以用（3 分）。

改进方法：核方法（2 分）与软间隔方法（2 分）

核方法的原理是，通过核函数将样本从原始空间映射到一个更高维的特征空间，使得样本在这个特征空间内线性可分（3 分）。

软间隔方法的原理是允许支持向量机在一些样本上出错（3 分）。

2. 集成一定能提升性能吗？下图中，分别判断（a） 和（b）集成后能否提升性能。

	测试例1	测试例2	测试例3
h_1	√	√	×
h_2	√	√	×
h_3	√	√	×
集成	√	√	×

(a)

	测试例1	测试例2	测试例3
h_1	√	√	×
h_2	×	√	√
h_3	√	×	√
集成	√	√	√

(b)

影响集成学习的性能的关键因素有哪些，以及是如何影响的？ 请枚举 1 个可以提高集成学习性能的方法。

答：
集成学习不一定能提升性能（2 分）。

（a）集成后不能提升性能（2 分），
（b）集成后可以提升性能（2 分）。

影响集成学习性能的关键因素是：
个体学习器准确性（2 分）、
个体学习器多样性（2 分）。

个体学习器准确性越高（2 分）、
个体学习器多样性越大（2 分），
则集成性能越好。

提高集成学习性能的方法：数据样本扰动、输入属性扰动、输出表示扰动、算法参数扰动。（1 分，命中 1 个即可）