试卷

2022-2023

1、简述有监督学习与无监督学习的概念，列举出对应的至少一种算法模型。

答：（1）监督学习：对具有标记的训练样本进行学习来建立从样本特征到标记的映射。例如：支持向量机、决策树、贝叶斯分类等。----5 分

（2）无监督学习：对没有标记的训练样本进行学习，以发现训练样本集中的结构性知识。聚类就是典型的无监督学习。----------5 分

2、解释“欠拟合”、“过拟合”这两个名词概念，并给出解决这两种问题的主要解决方案（每个问题至少一种）。

答：（1）过拟合：在统计学中，过拟合是指我们设计的模型过于紧密或精确的匹配了某特定数据，使得模型缺少泛化能力，而无法有效处理其他的、或未观测的数据的现象。----------4 分

解决方案：

- 使用正则化约束
- 提前结束训练
- 调整参数和超参数

等等（列出一种即可）------1 分

（2）欠拟合：欠拟合的概念恰恰与过拟合相反；它是指相对于数据而言，我们的预测模型过于简单，无法有效反应数据的特征规律，因此也缺少了泛化能力。----------4 分

解决方案：

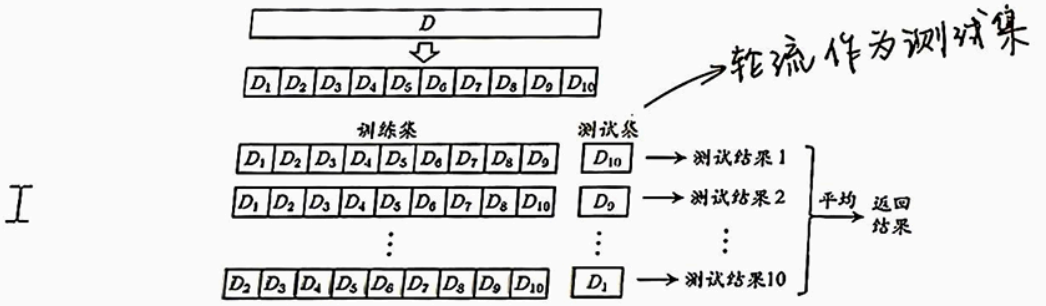
- 模型复杂化；
- 增加更多的特征，使输入数据具有更强的表达能力
- 调整参数和超参数

等等（列出一种即可）----------1 分

3、使用机器学习的方法训练模型时，要考虑合理的训练集和测试集，阐述留出法、K 折交叉验证法与自助法的原理。

答：（1）留出法：留出法是直接将数据集 D 划分为两个互斥的集合，其中一个作为训练集 S，另一个作为测试集 T。----------3 分

（2）K 折交叉验证法：就是将数据集 D 划分为 k 个大小相似、分层采样的互斥子集。----------4 分



（3）自助法：假设数据集 D 有 m 个样本，通过抽取放回的方式从数据集 D 中抽取 m 个样本。这抽取出的 m 个样本就是 D'，当然 D 中数据集肯定有部分样本从来没被抽到过，那么没被抽到过的这些数据集就能用作测试集 D－D'，训练集为 D'。----------3 分

4、决策树的预剪枝与后剪枝各有什么优缺点？

答：

（1）预剪枝

优点：思想简单，算法高效，可以降低过拟合风险，减少训练时间。-------3 分

缺点：可能存在欠拟合的风险。-------2 分

（2）后剪枝

优点：欠拟合风险小，泛化能力优于预剪枝。------3 分

缺点：相较于预剪枝，训练开销大。----------2 分

5、谈谈你对核函数的理解（从定义、基本思想、常见核函数的选择等至少两个角度）。

答：

（1）定义

核函数是支持向量机中一种非线性函数。低维输入空间又存在某个函数 K(x，x′），它恰好等于在高维空间中这个内积，即 K（ x，x′）=φ（ x）·φ（ x′），这样的函数 K(x，x′）称为核函数。

（2）基本思想

在原始特征空间中，数据可能呈现出复杂甚至非线性分布的情况，这时如果直接使用线性分类器进行分析，效果可能会很差。使用核函数，SVM 可以将原始空间中的特征映射到更高维度的空间中，在新的高

维空间中，数据点之间的欧式距离可以更好的反映它们之间的相似度。

（3）常见的核函数

- 线性核函数（Linear Kernel）
- 多项式核函数（Polynomial Kernel）
- 高斯核函数（Gaussian Kernel）
- 拉普拉斯核函数（Laplacian Kernel）
- Sigmoid 核函数（Sigmoid Kernel）

文本分类常用线性核函数

其他情况不明多选用高斯核函数

（以上任选 2 个角度阐述，每个角度 5 分）

二、思考题（每题 10 分，共 20 分）

1、给出 k 均值聚类算法的伪代码描述。

答案：

输入：样本集 $D = \{x_1, x_2, \ldots, x_m\}$;
聚类簇数 k.

过程：

1: $\{\mu_1, \mu_2, \ldots, \mu_k\}$
2: **repeat**
3: 令 $C_i = \varnothing$ $(1 \leqslant i \leqslant k)$
4: **for** $j = 1, 2, \ldots, m$ **do**
5: $d_{ji} = \|x_j - \mu_i\|_2$;
6: $\lambda_j = \arg\min_{i \in \{1,2,\ldots,k\}} d_{ji}$;
7: $C_{\lambda_j} = C_{\lambda_j} \cup \{x_j\}$;
8: **end for**
9: **for** $i = 1, 2, \ldots, k$ **do**
10: $\mu_i' = \frac{1}{|C_i|} \sum_{x \in C_i} x$;
11: **if** $\mu_i' \neq \mu_i$ **then**
12: 将当前均值向量 μ_i 更新为 μ_i'
13: **else**
14: 保持当前均值向量不变
15: **end if**
16: **end for**
17: **until** 当前均值向量均未更新

输出：簇划分 $C = \{C_1, C_2, \ldots, C_k\}$

k 均值算法

2、集成学习方法包括 bagging 和 boosting 两个大类，阐述 bagging 方法和 boosting 方法的基本原理，并对比两者在偏差-方差分解角度的主要关注点。

解：Bagging 算法过程如下：　　----------4 分

（1）从原始样本集中抽取训练集。每轮从原始样本集中使用 Bootstraping 的方法抽取 n 个训练样本，（在训练集中，有些样本可能被多次抽取到，而有些样本可能一次都没有被抽中）。共进行 k 轮抽取，得到 k 个训练集。

（2）每次使用一个训练集得到一个模型，k 个训练集共得到 k 个模型。

（3）对分类问题：将上步得到的 k 个模型采用投票的方式得到分类结果；对回归问题，计算上述模型的均值作为最后的结果。

三、计算题（共 30 分 ）

1、（10 分）一个 BP 神经网络为两层结构，网络的输入模式为 X，期望输出模式为 Y，输入层至隐含层的初始连接权重 W、隐含层至输出层的初始连接权重 V、隐含层神经元的阈值 θ 和输出层神经元的阈值 γ 如下：

$$X=\begin{pmatrix}1\\3\end{pmatrix}\quad Y=\begin{pmatrix}0.95\\0.95\end{pmatrix}\quad W=\begin{pmatrix}1&2\\-2&0\end{pmatrix}\quad V=\begin{pmatrix}1&1\\0&-2\end{pmatrix}\quad \theta=\begin{pmatrix}3\\-1\end{pmatrix}\quad \gamma=\begin{pmatrix}-2\\3\end{pmatrix}$$

（1）试画出该 BP 网络的拓扑结构。

（2）采用标准 BP 算法实现对该 BP 网络的一次前向训练（激活函数为 Sigmoid 函数），请写出隐含层各神经元的输入和输出、输出层各神经元的输入和输出。（注：$e^{-3}\approx0.050$，$e^{-2}\approx0.14$，$e^{4.9}\approx134.29$，$e^{6}\approx403.43$，$e^{7}\approx1096.63$，$e^{8}\approx2981.00$）

Sigmoid 函数的公式为：$S(x)=\dfrac{1}{1+e^{-x}}$

- 输出层各神经元的输入和输出。　　画图-手工

$$X=\begin{pmatrix}1\\3\end{pmatrix}\quad Y=\begin{pmatrix}0.95\\0.95\end{pmatrix}\quad W=\begin{pmatrix}1&2\\-2&0\end{pmatrix}\quad V=\begin{pmatrix}1&1\\0&-2\end{pmatrix}\quad \theta=\begin{pmatrix}3\\-1\end{pmatrix}\quad \gamma=\begin{pmatrix}-2\\3\end{pmatrix}$$

- 隐藏层：$S=W^TX-\theta$，$B=f(S)$

$$s_1=w_{11}x_1+w_{21}x_2-\theta_1=1*1+(-2)*3-3=-8, b_2=f(s_1)=1/(1+e^{8})\approx0.00034$$

$$s_2=w_{12}x_1+w_{22}x_2-\theta_2=2*1+0*3-(-1)=3, b_2=f(s_2)=1/(1+e^{-3})\approx0.95$$

- 输出层：$L=V^TB-\gamma$，$C=f(L)$

$$l_1=v_{11}b_1+v_{21}b_2-\gamma_1=1*0.00034+0*0.95-(-2)\approx2.00$$

$$c_1=f(l_1)=1/(1+e^{-2})\approx0.88$$

$$l_2=v_{12}b_1+v_{22}b_2-\gamma_2=1*0.00034+(-2)*0.95-3\approx-4.90$$

$$c_2=f(l_2)=1/(1+e^{4.9})\approx0.0074$$

2、（8 分）假设某公司每天进出 100 人，其中 80 个好人，20 个小偷，保安需要将这些小偷抓出来，其中某保安 A 的表现如表 2 所示，保安 B 的表现如表 3 所示，请计算每个保安的查准率与查全率，并判断在该场景下，哪位保安的表现更好一些（希望尽可能将所有小偷抓出来）。

表 1 保安 A 的表现

	实际上是小偷	实际上是好人	合计
抓住的小偷	5	1	6
放走的好人	15	79	94
合计	20	80	100

表 2 保安 B 的表现

	实际上是小偷	实际上是好人	合计
抓住的小偷	10	20	30
放走的好人	10	60	70
合计	20	80	100

3、（12 分）仓库中有一批服装，为了更好的销售，需要根据服装的款式 X_1（1：上衣；2：裤子）和尺码 X_2（S：小码；M:中码；L:大码）对这批服装进行类别标记（1：打折销售；-1：不打折）。因此，每一件服装样本有两个属性 X_1，X_2，样本类别标记使用 Y 表示，数据如表 3。

问题：若有一个服装样本（裤子，小码）x=[2,S]，请使用朴素贝叶斯分类器模型预测该样本的类别标记（打折销售还是不打折销售？）

提示公式：$$P(c|x) = P(c)\prod_{i=1}^{d} P(x_i|c)$$

表 3

X_1	X_2	Y
1	S	-1
1	M	1

表3

X_1	X_2	Y
1	S	-1
1	M	-1
1	S	1
1	S	-1
2	M	-1
2	L	1
2	L	1
3	L	1
3	M	1
3	M	1
3	L	1
3	L	-1

2024

- 一、选择题（每空2分，共20分）
- 二、简答题（共40分，每小题10分）

1、请对比假设空间与版本空间的区别。（10分）

2、在机器学习领域，我们经常要求解目标函数的最小值，请列出学过的至少2个求解最小值的方法，并做简单解释说明。（10分）

3、请简述样本类别不平衡问题的概念及解决方法。（10分）

4、请简述回归树的基本原理并且说明其与决策树的区别。（10分）

- 三、计算题（30分，每小题15分）
- 四、思考题（10分）

- 一、选择题（每空2分，共20分）
- 二、简答题（共40分，每小题10分）
- 三、计算题（30分，每小题15分）

1、（15分）如下8个样本点聚为三类：A1(1,2)、A2(3,1)、A3(8,4)、B1(5,8)、B2(4,1)、B3(6,4)、C1(3,5)、C2(4,9)，距离函数是欧氏距离，并假设初始中心为A1，B1，C1。采用K均值算法，求在第一次循环后的三个聚类组成及相应的聚类中心。

2、（15）假设给定有图的数据集，其中A,B,C为二值随机变量，Y为标记（预测值）。根据给定的训练集，使用朴素贝叶斯分类器计算A=0，B=0，C=1的预测值。

- 四、思考题（10分）

练习题

– 7.1 极大似然法估算类条件概率

– 试使用极大似然法估算西瓜数据集3.0中前3个属性的类条件概率

表 4.3 西瓜数据集 3.0

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

色泽：

P(青绿|好瓜)=3/8,P(青绿|坏瓜)=3/9

P(乌黑|好瓜)=4/8,P(乌黑|坏瓜)=2/9

P(浅白|好瓜)=1/8,P(浅白|坏瓜)=4/9

根蒂：

P(蜷缩|好瓜)=5/8,P(蜷缩|坏瓜)=3/9

P(稍蜷|好瓜)=3/8,P(稍蜷|坏瓜)=4/9

P(硬挺|好瓜)=0/8,P(硬挺|坏瓜)=2/9

敲声：

P(浊响|好瓜)=6/8,P(浊响|坏瓜)=4/9

P(沉闷|好瓜)=2/8,P(沉闷|坏瓜)=3/9

P(清脆|好瓜)=0/8,P(清脆|坏瓜)=2/9

– 3.7 最优的ECOC

3.7 令码长为 9, 类别数为 4, 试给出海明距离意义下理论最优的 ECOC 二元码并证明之.

答案：当码长为 2^{d-1}-1 时，至少可以使 d 个类别达到最优间隔 d，其的海明距离为 2^{d-2}。

穷举编码"exhaustive codes":

第 1 行：2^{d-1}-1 个"1"

第 2 行：2^{d-2} 个"0"，之后是 2^{d-2}-1 个"1"

第 3 行：2^{d-3} 个"0"，之后是 2^{d-3} 个"1",继续至结尾

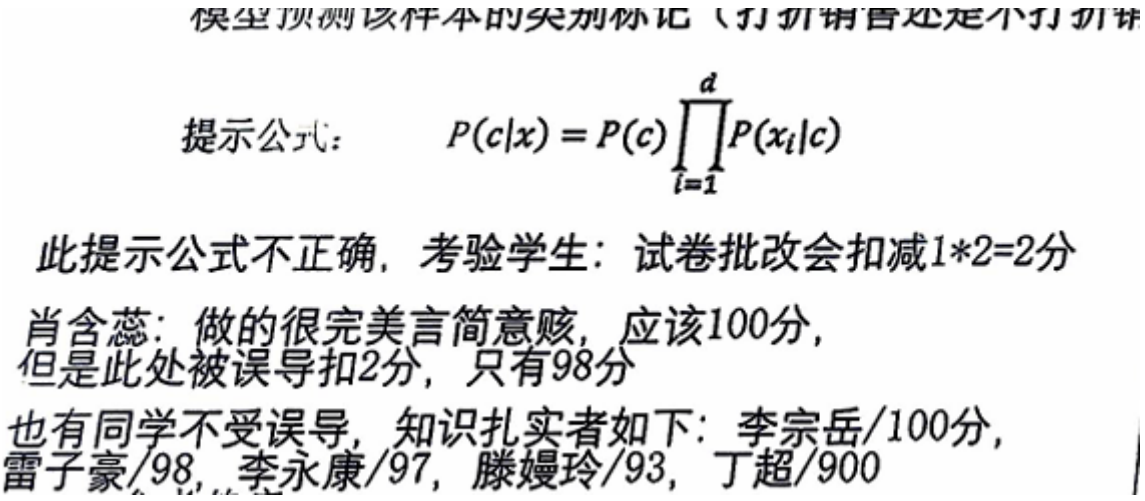
...

第 d 行：1 个"0"，之后是 2^{d-3} 个"1",继续至结尾

– 取d=4,则码长为7，类别数为4，间隔至少为4。如下：

	f0	f1	f2	f3	f4	f5	f6
c1	1	1	1	1	1	1	1
c2	0	0	0	0	1	1	1
c3	0	0	1	1	0	0	1
c4	0	1	0	1	0	1	0

考前提示



给的公式可能有问题，自己注意一下