# 模型评估

## 例：保安的能力评估

- 保安对进出公司的人员进行盘查，识别其中的小偷。保安有可能犯两类错误：
  - 1. 把好人误认为小偷，称为假小偷（与之相反称为真小偷）。
  - 2. 把小偷误认为好人，称为假好人（与之相反称为真好人）。
- 保安优秀与否可以按照如下的两个标准来评判：
  - 1. 抓住的小偷中真小偷的比例尽量的高。
  - 2. 宁可错抓好人也不放过小偷。
- 标准1为精准率（Precision）
- 标准2为召回率（Recall）

$$Precision = \frac{\text{抓住的真小偷数量}}{\text{抓住的真小偷数量} + \text{抓住的假小偷数量}}$$

$$Recall = \frac{\text{抓住的真小偷数量}}{\text{抓住的真小偷数量} + \text{放走的假好人数量}}$$

- 假设某公司每天进出100人，其中80个好人，20个小偷，某保安A的表现如下：

| | 实际上是小偷 | 实际上是好人 | 合计 |
|---|---|---|---|
| 抓住的小偷 | 5 | 1 | 6 |
| 放走的好人 | 15 | 79 | 94 |
| 合计 | 20 | 80 | 100 |

- 保安共计抓住6个小偷，其中5人是真小偷，另外1人是假小偷（好人被误抓），依据公式可知，该保安的Precision=5/(5+1)=5/6≈88.3%。
- 看上去这名保安抓人的准确性挺强，但他是一名好保安吗？

- 来看看召回率的计算。Recall=5/(5+15)=1/4=25%。放走的假好人就是被保安误认为好人的小偷。所以Recall的分母总是等于小偷的总数（而Precision的分母是抓住的人的总数）。从召回率可以看出，这名保安放走了3/4的小偷，这实在不能算优秀的保安。
- 某保安B的表现如下：

| | 实际上是小偷 | 实际上是好人 | 合计 |
|---|---|---|---|
| 抓住的小偷 | 20 | 20 | 40 |
| 放走的好人 | 0 | 60 | 60 |
| 合计 | 20 | 80 | 100 |

- 根据上述公式计算，Precision=50%，Recall=100%。虽然精度不高，误抓了不少好人，但这名保安抓住了全部小偷。

- 理想的保安：

| | 实际上是小偷 | 实际上是好人 | 合计 |
|---|---|---|---|
| 抓住的小偷 | 20 | 0 | 20 |
| 放走的好人 | 0 | 80 | 80 |
| 合计 | 20 | 80 | 100 |

- Precision=Recall=100%。
- 将Precision和Recall放到一个公式中，就构成了F1 Score，是精度和召回率的调和均值，两者都高则F1高，其公式如下：

$$F_1 = \frac{2}{\frac{1}{Precision} + \frac{1}{Recall}} = \frac{TP}{TP + \frac{FN+FP}{2}}$$

保安2.0版本：

2、（8 分）假设某公司每天进出 100 人，其中 80 个好人，20 个小偷，保安需要将这些小偷抓出来，其中某保安 A 的表现如表 2 所示，保安 B 的表现如表 3 所示，请计算每个保安的**查准率**与**查全率**，并判断在该场景下，哪位保安的表现更好一些（希望尽可能将所有小偷抓出来）。

表 1 保安 A 的表现

| | 实际上是小偷 | 实际上是好人 | 合计 |
|---|---|---|---|
| 抓住的小偷 | 5 | 1 | 6 |
| 放走的好人 | 15 | 79 | 94 |
| 合计 | 20 | 80 | 100 |

表 2 保安 B 的表现

| | 实际上是小偷 | 实际上是好人 | 合计 |
|---|---|---|---|
| 抓住的小偷 | 10 | 20 | 30 |
| 放走的好人 | 10 | 60 | 70 |
| 合计 | 20 | 80 | 100 |

参考答案：

- 保安 A：保安共计抓住 6 个小偷，其中 5 人是真小偷，另外 1 人是假小偷（好人被误抓），依据公式可知

  Precision=5/(5+1)=5/6≈88.3%

  Recall=5/20=25%

- 某保安 B：根据上述公式计算：

  Precision=10/30=33.3%

  Recall=10/20=50%

  保安 B 表现更好。

# 决策树

- 以有无房子作为分裂属性计算它的Gini值

| 有房 | 无房 | 拖欠贷款 |
| --- | --- | --- |
| 0 | 3 | 是 |
| 3 | 4 | 否 |

$$Gini(有房)=1-(3/3)^2-(0/3)^2=0$$

$$Gini(无房)=1-(4/7)^2-(3/7)^2=0.4849$$

$$Gini=0.3\times0+0.7\times0.4898=0.343$$

## 处理多分类属性

| | 单身或已婚 | 离异 |
| --- | --- | --- |
| 否 | 6 | 1 |
| 是 | 2 | 1 |

$$Gini(t_1)=1-(6/8)^2-(2/8)^2=0.375$$
$$Gini(t_2)=1-(1/2)^2-(1/2)^2=0.5$$
$$Gini=8/10\times0.375+2/10\times0.5=0.4$$

| | 单身或离异 | 已婚 |
| --- | --- | --- |
| 否 | 3 | 4 |
| 是 | 3 | 0 |

$$Gini(t_1)=1-(3/6)^2-(3/6)^2=0.5$$
$$Gini(t_2)=1-(4/4)^2-(0/4)^2=0$$
$$Gini=6/10\times0.5+4/10\times0=0.3$$

| | 离异或已婚 | 单身 |
| --- | --- | --- |
| 否 | 5 | 2 |
| 是 | 1 | 2 |

$$Gini(t_1)=1-(5/6)^2-(1/6)^2=0.2778$$
$$Gini(t_2)=1-(2/4)^2-(2/4)^2=0.5$$
$$Gini=6/10\times0.2778+4/10\times0.5=0.3667$$

1. 这里给一个基于信息熵构建决策树的例子：

   假设我们有一个二分类问题，要根据两个特征 "年龄" 和 "收入" 来预测一个人是否会购买某个产品。我们的训练集如下：

   样本　年龄　收入　购买
   1　青年　高　是
   2　青年　低　是
   3　中年　低　是
   4　老年　低　否
   5　老年　高　否

首先，计算原始数据集的信息熵。在这个例子中，样本总数为5，其中2个样本属于"是"类别，3个样本属于"否"类别。因此，原始数据集的信息熵为：

$$H(D) = -3/5 * log_2(3/5) - 2/5 * log_2(2/5) = 0.971$$

接下来，我们计算每个特征的信息增益，并选择具有最大信息增益的特征作为根节点。首先，计算特征"年龄" 的信息增益：

- 当 "年龄" 为 "青年" 时，有2个样本属于"是"类别，没有样本属于"否"类别。因此,$H(D_{青年}) = 0$
- 当 "年龄" 为 "中年" 时，有1个样本属于"是"类别，1个样本属于"否"类别。因此，$H(D_{中年}) = 1$
- 当 "年龄" 为 "老年" 时，有0个样本属于"是"类别，2个样本属于"否"类别。因此，$H(D_{老年}) = 0$

因此，“年龄”特征的信息增益为：

$$Gain(D, 年龄) = H(D) - (2/5 * 0 + 1/5 * 1 + 2/5 * 0) = 0.171$$

同样方法计算其他两个特征的。

# 神经网络

1、（10 分）一个 BP 神经网络为两层结构，网络的输入模式为 $X$，期望输出模式为 $Y$，输入层至隐含层的初始连接权重 $W$、隐含层至输出层的初始连接权重 $V$、隐含层神经元的阈值 $\theta$ 和输出层神经元的阈值 $\gamma$ 如下：

$$X=\begin{pmatrix}1\\3\end{pmatrix}\quad Y=\begin{pmatrix}0.95\\0.95\end{pmatrix}\quad W=\begin{pmatrix}1&2\\-2&0\end{pmatrix}\quad V=\begin{pmatrix}1&1\\0&-2\end{pmatrix}\quad \theta=\begin{pmatrix}3\\-1\end{pmatrix}\quad \gamma=\begin{pmatrix}-2\\3\end{pmatrix}$$

（1）试画出该 BP 网络的拓扑结构。

（2）采用标准 BP 算法实现对该 BP 网络的一次前向训练（激活函数为 Sigmoid 函数），请写出隐含层各神经元的输入和输出、输出层各神经元的输入和输出。（注：$e^{-3} \approx 0.050$，$e^{-2} \approx 0.14$，$e^{4.9} \approx 134.29$，$e^{6} \approx 403.43$，$e^{7} \approx 1096.63$，$e^{8} \approx 2981.00$）

Sigmoid 函数的公式为：$S(x) = \frac{1}{1+e^{-x}}$

1. 解：

（1）输入层 2 个节点，输出层 2 个节点，隐含层 2 个节点，层与层之间全连接，激活函数选取 Sigmoid 函数。（4 分）

（2）1 次前向训练过程如下：

隐含层输入：（3 分）

$$s_1 = w_{11}x_1 + w_{21}x_2 - \theta_1 = 1*1+(-2)*3-3 = -8, b_2 = f(s_1) = 1/(1+e^{8}) \approx 0.00034$$

$$s_2 = w_{12}x_1 + w_{22}x_2 - \theta_2 = 2*1+0*3-(-1) = 3, b_2 = f(s_2) = 1/(1+e^{-3}) \approx 0.95$$

输出层输入：（3 分）

$$l_1 = v_{11}b_1 + v_{21}b_2 - \gamma_1 = 1*0.00034+0*0.95-(-2) \approx 2.00$$

$$c_1 = f(l_1) = 1/(1+e^{-2}) \approx 0.88$$

$$l_2 = v_{12}b_1 + v_{22}b_2 - \gamma_2 = 1*0.00034+(-2)*0.95-3 \approx -4.90$$

$$c_2 = f(l_2) = 1/(1+e^{4.9}) \approx 0.0074$$

过于.0

# svm

问题：训练集有3个数据点，其中两个正例点：$\mathrm{x}_1 = (3,3)^{\mathrm{T}}, \mathrm{x}_2 = (4,3)^{\mathrm{T}}$，一个负例点：$\mathrm{x}_3 = (1,1)^{\mathrm{T}}$。试求最大间隔分离超平面（在二维空间即为一条直线）。

构建模型：设超平面方程为$\mathrm{w}_1\,\mathrm{x} + \mathrm{w}_2\,\mathrm{y} + \mathrm{b} = 0$，则上述问题等价于下列约束最优化问题：

$$\min_{\mathrm{w_i},\mathrm{b},\mathrm{i}=1,2} \frac{1}{2}(\mathrm{w}_1^2 + \mathrm{w}_2^2)$$

s.t.

$$3\mathrm{w}_1 + 3\mathrm{w}_2 + \mathrm{b} >= 1$$
$$4\mathrm{w}_1 + 3\mathrm{w}_2 + \mathrm{b} >= 1$$
$$-\mathrm{w}_1 - \mathrm{w}_2 - \mathrm{b} >= 1$$

构建拉格朗日函数：

$$\mathcal{L}(\mathrm{w}_1, \mathrm{w}_2, \mathrm{b}, \mu_1, \mu_2, \mu_3) = \frac{1}{2}(\mathrm{w}_1^2 + \mathrm{w}_2^2) + \mu_1(1 - 3\mathrm{w}_1 - 3\mathrm{w}_2 - \mathrm{b}) + \mu_2(1 - 4\mathrm{w}_1 - 3\mathrm{w}_2 - \mathrm{b}) + \mu_3(\mathrm{w}_1 + \mathrm{w}_2 + \mathrm{b} + 1)$$

求偏微分：

$$\frac{\partial \mathcal{L}}{\partial \mathrm{w}_1} = \mathrm{w}_1 - 3\mu_1 - 4\mu_2 + \mu_3 = 0$$
$$\frac{\partial \mathcal{L}}{\partial \mathrm{w}_2} = \mathrm{w}_2 - 3\mu_1 - 3\mu_2 + \mu_3 = 0$$
$$\frac{\partial \mathcal{L}}{\partial \mathrm{b}} = -\mu_1 - \mu_2 + \mu_3 = 0$$

用KKT条件对其进行约束：

$$3\mathrm{w}_1 + 3\mathrm{w}_2 + \mathrm{b} - 1 >= 0$$
$$4\mathrm{w}_1 + 3\mathrm{w}_2 + \mathrm{b} - 1 >= 0$$
$$-\mathrm{w}_1 - \mathrm{w}_2 - \mathrm{b} - 1 >= 0$$
$$\mu_\mathrm{i} >= 0, \mathrm{i} = 1,2,3$$
$$\mu_1(3\mathrm{w}_1 + 3\mathrm{w}_2 + \mathrm{b} - 1) = 0$$
$$\mu_2(4\mathrm{w}_1 + 3\mathrm{w}_2 + \mathrm{b} - 1) = 0$$
$$\mu_3(-\mathrm{w}_1 - \mathrm{w}_2 - \mathrm{b} - 1) = 0$$

分情况进行讨论：
1）假设$\mu_1 = 0$，可以计算得$w_1 = 3\mu_2, w_2 = 2\mu_2$，带入三个不等式得：$b >= 1 - 15\mu_2, b >= 1 - 18\mu_2, b <= -5\mu_2 - 1$。
此时$\mu_2 = \mu_3 >= 1/5$，则$4w_1 + 3w_2 + b - 1 = 0$，$-w_1 - w_2 - b - 1 = 0$，即$18\mu_2 + b - 1 = 0, -5\mu_2 - b - 1 = 0$，即$\mu_2 = 2/13$，矛盾，所以$\mu_1$大于0。

2）假设$\mu_2 = 0$，可以计算得$w_1 = w_2 = 2\mu_1 > 0$，带入三个不等式（有两个已经变成了等式）得：$b = 1 - 12\mu_1, b >= 1 - 14\mu_1, b = -4\mu_1 - 1$。
此时$\mu_2 = 0$，$\mu_1 = \mu_3 = 1/4, w_1 = w_2 = 1/2, b = -2$。

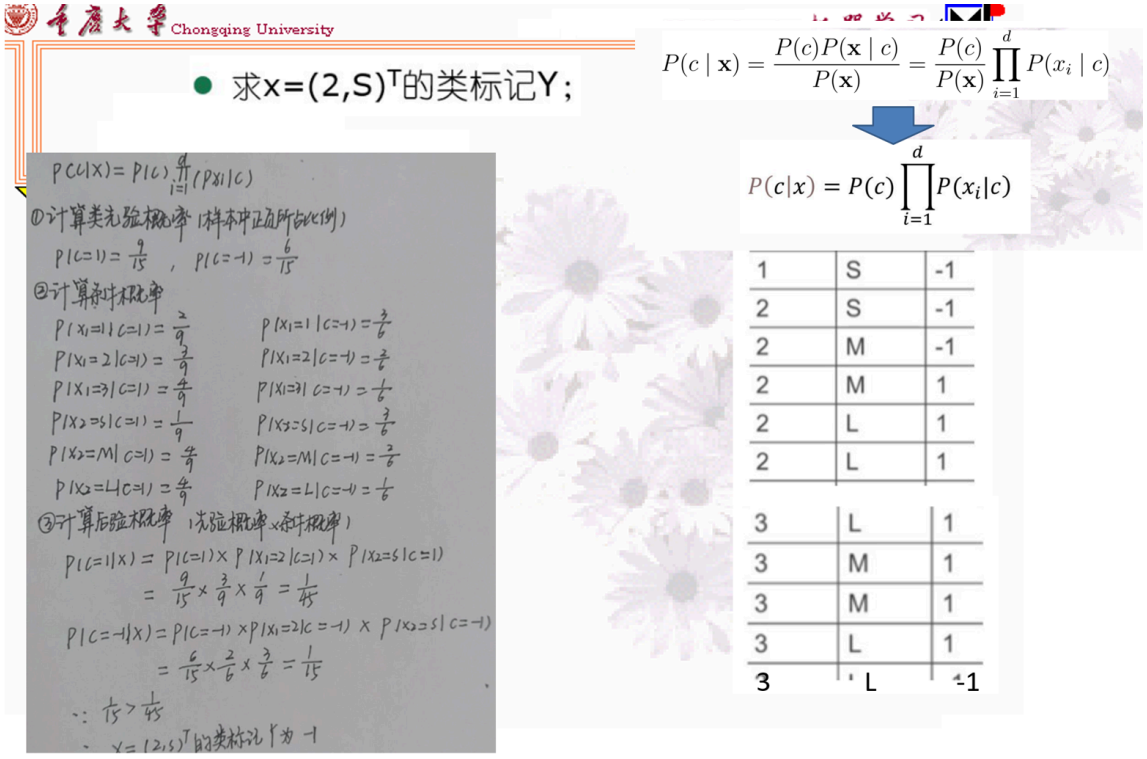
假设$\mu_2$不等于0，则$4w_1 + 3w_2 + b - 1 = 0$，$3w_1 + 3w_2 + b - 1 = 0$，即$w_1 = 0$，易得$\mu_3 = 0, \mu_2 = -\mu_1$，显然出现了矛盾，此种情况不可能。

3）假设$\mu_3 = 0$，由前面的条件易知$\mu_1 = 0$，出现了矛盾。

综上所述：
$\mu_2 = 0, \mu_1 = \mu_3$但不等于0，此时$\mu_2 = 0$，$\mu_1 = \mu_3 = 1/4, w_1 = w_2 = 1/2, b = -2$。

所以超平面方程为$1/2x + 1/2y - 2 = 0$。

# 朴素贝叶斯



# K-means

**5.k-均值算法例题：**

题目给出

1. 簇的数目k=2
2. 下表数据表（n=8）行数据

| 序号 | 属性1 | 属性2 |
|---|---|---|
| 1 | 1 | 1 |
| 2 | 2 | 1 |
| 3 | 1 | 2 |
| 4 | 2 | 2 |
| 5 | 4 | 3 |
| 6 | 5 | 3 |
| 7 | 4 | 4 |
| 8 | 5 | 4 |

解：

1. 第一次迭代：由于最终结果要为**k=2个簇**,所以第一次迭代先**随机找两行数据**，如第1行和第3行当为初始点，

   ①要将全部数据分为两个簇，运用欧氏距离，让2,4,5,6,7,8依次和1和3分别进行距离计算，然后比较，离1近则和1合并，离3近则和3合并，这次迭代得到两个簇{1,2}和{3,4,5,6,7,8}

   ②对产生的簇分别计算平均值，得到平均值点

   对于{1,2},属性1：(1+2)/2=1.5,属性2：(1+1)/2=1,则平均值点为(1.5,1)

   对于{3,4,5,6,7,8},属性1：(1+2+4+5+4+5)/6=3.5,属性2：(2+2+3+3+4+4)/6=3，则平均值点为(3.5,3)
2. 第二次迭代：再将表中全部数据按离平均值点(1.5,1)和(3.5,3)最近的原则，重新分配。得到两个新的簇：{1,2,3,4}和{5,6,7,8}；

   再重新计算簇平均值点，得到新的平均值为(1.5,1.5)和(4.5,3.5)
3. 第三次迭代：再将表中全部数据按离新的平均值点(1.5,1.5)和(4.5,4.5)最近的原则，重新分配。得到两个新的簇：{1,2,3,4}和{5,6,7,8}；这里发现与第二次迭代得到的两个簇相比,没有出现新的簇，则算法结束。

**最终的到两个簇{1,2,3,4}和{5,6,7,8}。**

# 灵魂拷问

请简述什么是假设空间，什么是版本空间。

请简述训练误差、测试误差、泛化误差。

– 训练误差小的时候，泛化误差就一定小吗？

对数几率回归解决的是回归问题还是二分类问题？

– 训练对数几率回归的方法是什么？

朴素贝叶斯分类器解决了什么障碍？其关键假设是什么？

请简述局部极小与全局极小。

简述有监督学习与无监督学习的概念，列举出对应的至少一种算法模型。

解释“欠拟合”、“过拟合”这两个名词概念，并给出解决这两种问题的主要解决方案（每个问题至少一种）。

使用机器学习的方法训练模型时，要考虑合理的训练集和测试集，阐述留出法、K折交叉验证法与自助法的原理。

决策树的预剪枝与后剪枝各有什么优缺点？

谈谈你对核函数的理解（从定义、基本思想、常见核函数的选择等至少两个角度）

给出 k 均值聚类算法的伪代码描述。

集成学习方法包括 bagging 和 boosting 两个大类，阐述 bagging 方法和 boosting 方法的基本原理，并对比两者在偏差-方差分解角度的主要关注点。

支持向量机基本型解决的是回归问题还是二分类问题？如果超平面不可以将训练样本正确分类，支持向量机基本型方法还可以用吗？如果不可以用，有哪些改进方法？这些改进方法的基本原理是什么？

集成一定能提升性能吗？影响集成学习的性能的关键因素有哪些，以及是如何影响的？ 请列举1个可以提高集成学习性能的方法。